



沈阳航空航天大学

硕士学位论文

论文题目 大数据背景下供应链需求预测与牛鞭效应的研究

研究生 刘垭

专业 管理科学与工程

研究方向 供应链管理

指导教师 荆浩（教授）

二零一八年三月

原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立完成的。除文中已经注明引用的内容外，本论文不包含其他个人或集体已经发表或撰写过的作品或成果，也不包含本人为获得其他学位而使用过的成果。对本文研究做出重要贡献的个人或集体均已在论文中进行了说明并表示谢意。本声明的法律后果由本人承担。

论文作者签名：刘垚

2018年3月15日

版权授权说明

本人授权学校“有权保留送交学位论文的原件，允许学位论文被查阅和借阅，学校可以公布学位论文的全部或部分内容，可以影印、缩印或其他复制手段保存学位论文”；愿意将本人学位论文电子版提交给研究生部指定授权单位收录和使用。学校必须严格按照授权对论文进行处理，不得超越授权对毕业论文进行任意处置。

作者：刘娅

2018年3月16日

指导教师：刘浩

2018年3月16日

分类号_____

密级_____公开_____

UDC_____

学 位 论 文

大数据背景下供应链需求预测与牛鞭效应的研究

研 究 生 姓 名 ： 刘垭

学科专业名称 ： 管理科学与工程

研 究 方 向 ： 供应链管理

论 文 类 型 ： 应用研究

申 请 学 位 ： 管理学硕士

指导教师姓名 ： 荆浩

指导教师职称 ： 教授

指导教师单位 ： 沈阳航空航天大学

论文提交日期 ： 2018 年 03 月 05 日

论文答辩日期 ： 2018 年 03 月 14 日

沈 阳 航 空 航 天 大 学

2018 年 03 月

SHENYANG AEROSPACE UNIVERSITY

THESIS FOR MASTER'S DEGREE

**RESEARCH ON DEMAND FORECAST
AND BULLWHIP EFFECT OF SUPPLY
CHAIN IN BIG DATA**

Candidate: Ya Liu

Supervisor: Hao Jing

Specialty: Management Science and Engineering

Date: March 2018

摘 要

随着大数据的兴起,互联网技术与各个领域的快速融合,使得供应链的结构发生新的变化,为供应链的发展开拓了新的方向。由于在大数据的环境下数据的获取更加快速便捷,使得各个企业在新供应链体系中实现信息共享成为可能。在供应链管理中,需求预测是贯穿整个供应链必不可少的一个环节。当缺乏准确的市场需求信息时,在信息向供应链上流传递的过程中产生的牛鞭效应将会影响供应链中各个环节的协调与控制,极大地削弱了整个供应链的竞争力。然而在大数据背景下传统的预测方法已经无法达到满意的预测精度,这给供应链管理带来了巨大的挑战。基于上述问题,本文提出了大数据背景下供应链需求预测与牛鞭效应的研究课题,对于适应新的市场需求变化、提高企业的核心竞争力、实现供应链整体效益最优具有深刻的理论与实践意义。

本文将大数据与供应链管理相结合,构建了一类大数据背景下的供应链模型,并在此基础上进一步分析了供应链的需求预测与牛鞭效应,论文的主要创新和具体工作如下:

(1) 针对大数据背景下供应链所具备的特点,构建新的供应链体系。引入 Agent 理论采用 Multi-Agent 系统抽象模拟出大数据背景下的供应链结构模型。

(2) 根据大数据背景下供应链的结构和市场需求特征,提出了基于遗传算的支持向量机预测模型。首先建立一般的传统支持向量机模型,讨论模型中参数对拟合预测的影响。然后在充分考虑在大数据背景下企业需快速反应市场需求的特点以及传统的预测模型存在较大预测误差的基础上,提出利用遗传算法对原有模型的参数进行优化改进,构造基于遗传算法的支持向量机预测模型。最后通过对某电子产品的销售数量进行拟合预测验证了新模型的预测性能以及对供应链中牛鞭效应的影响。

(3) 针对大数据背景下供应链中影响市场需求因素繁多的特点,采用信息熵理论选取主要特征因素,考虑了多个变量的相互影响,在此基础上提出了基于多变量支持向量机的需求预测方法,最大程度挖掘了各种有效信息。由于高维下支持向量机预测模型缺乏推广能力,预测误差较高,本文采用 BP 神经网络对多变量支持向量机预测结果进行误差调整。最后通过计算机模拟仿真进行算例分析。结果表明,运用多变量支持向量机预测模型对多个因素影响下的市场需求具有良好的预测性能,有效地提高了预测精度。并且通过对多变量支持向量机预测模型下牛鞭效应的分析说明了优化需求预测可以有效地缓解供应链中的牛鞭效应。

关键词: 大数据; 供应链; 需求预测; 牛鞭效应; 支持向量机

Abstract

With the rise of big data and the Internet technology rapidly merges into various fields, it has made new changes in the structure of the supply chain and reclaimed some new directions for the development of the supply chain. Due to the faster and more convenient acquisition of data in big data, it is possible for enterprises to achieve information sharing in the new supply chain. In the supply chain management, demand forecasting is an essential part of the whole supply chain. When there is a lack of accurate market demand information, the bullwhip effect that generated in the process of information transfer to the upstream of the supply chain will affect the coordination and control of each link in the supply chain, greatly weakening the competitiveness of the whole supply chain. However, traditional forecasting methods have been unable to obtain satisfactory prediction accuracy under the background of big data, which has brought great challenges to the supply chain management. Based on the above problems, this paper propose the research topic of the supply chain demand forecasting and the bullwhip effect in big data, which has profound theoretical and practical significance for adapting to the new market demand changes, improving the core competitiveness of enterprises, and achieving the best overall efficiency of the supply chain.

This paper combines supply chain management with big data to build a type of supply chain model in big data. Based on this, we further analyse supply chain demand forecasting and the bullwhip effect. The main innovations and specific work of the paper are as follows:

(1) According to the characteristics of the supply chain in the background of big data, we build a new supply chain system, and introduce Agent theory to abstractly simulate the supply chain structure model in big data with Multi-Agent system.

(2) According to the structure of the supply chain and the characteristics of the market demand in the background of big data, we propose a support vector machine prediction model based on genetic algorithm, Firstly the general traditional model of support vector machine is established to discuss the influence of parameters in the model on the fitting prediction. Then on the basis of fully considering the characteristic which enterprise has to quick response to market demand and the large prediction error of the traditional predictive model in big data, we use a genetic algorithm to optimize and improve the parameters of the original model, and construct the vector machine prediction model based on genetic algorithm. Finally, we verify the prediction performance of the new model and the effect on the bullwhip effect in the supply chain by means of the fitting prediction of the sales quantity of an electronic product.

(3) According to the characteristics that many factors influence the market demand in the supply chain under the background of big data, the information entropy theory is adopted to select the main characteristic factors and to consider the mutual influence of multiple

variables. On the basis of this, we propose a demand forecasting method based on multivariable support vector machines to maximize the mining of a variety of effective information. Because the prediction model of the support vector machine lacks generalization capability and has a high prediction error in high dimensions, this paper uses BP neural network to adjust the error of prediction results for the multivariable support vector machines. Finally, we use the computer simulation to accomplish the example analysis. The results showed that the multivariate support vector machine prediction model has better prediction performance for the market demand under the influence of the multiple factors, and effectively improve the prediction accuracy. Then, we find that the optimization demand forecast can effectively mitigate the bullwhip effect in the supply chain. by analyzing the bullwhip effect in the multivariate support vector machine prediction model.

Keywords: big data; supply chain; demand forecasting; bullwhip effect; support vector machine

目 录

摘 要	I
ABSTRACT	II
第 1 章 绪论	1
1.1 研究背景	1
1.2 本文研究目的与意义	2
1.2.1 本文的研究目的	2
1.2.2 本文的研究意义	3
1.3 国内外研究现状	4
1.3.1 供应链牛鞭效应的研究现状	4
1.3.2 需求预测的研究现状	6
1.4 本文的研究内容及创新点	7
1.4.1 本文的研究内容	7
1.4.2 本文的创新点	8
第 2 章 相关理论基础	9
2.1 大数据概述	9
2.2 供应链与供应链管理	11
2.2.1 供应链	11
2.2.2 供应链管理	12
2.3 需求预测与牛鞭效应	14
2.3.1 供应链中的需求预测	14
2.3.2 供应链中的牛鞭效应	16
2.4 本章小结	16
第 3 章 大数据背景下基于 MULTI-AGENT 系统的供应链模型	17
3.1 基于大数据的供应链体系架构	17
3.2 AGENT 系统与 MULTI-AGENT 系统	18
3.3 基于 MULTI-AGENT 系统的供应链	20
3.4 本章小结	21
第 4 章 大数据背景下基于遗传算法的支持向量机需求预测与牛鞭效应的研究	22

4.1 支持向量机预测模型	22
4.1.1 线性可分支持向量机	22
4.1.2 支持向量机需求预测模型的构建	24
4.1.3 支持向量机模型的核函数及其参数选择	27
4.2 基于遗传算法的支持向量机预测模型的优化	28
4.2.1 遗传优化算法	28
4.2.2 遗传算法优化支持向量机参数	30
4.3 实例分析	31
4.3.1 需求预测分析	31
4.3.2 牛鞭效应分析	34
4.4 本章小结	36
第5章 大数据背景下基于多变量支持向量机的需求预测与牛鞭效应 的研究	37
5.1 多变量支持向量机需求预测模型	37
5.1.1 影响因素选取	38
5.1.2 多变量支持向量机预测模型	39
5.1.3 BP 神经网络误差修正	40
5.2 实例分析	41
5.2.1 需求预测分析	41
5.2.2 牛鞭效应分析	46
5.3 本章小结	48
结论	49
参考文献	51
致谢	53
攻读硕士期间发表（含录用）的学术论文	54

第1章 绪论

1.1 研究背景

近年来,随着经济全球化与信息技术的迅猛发展,社会环境变得越来越复杂,企业之间的竞争形势也愈加严峻。为了巩固自身的竞争优势、抢占市场,企业必须迅速对顾客需求做出响应。然而由于错综复杂的社会关系和瞬息万变的市场需求大大增加了企业在生产运作中面临的不确定性,这导致供应链中企业需要付出超额的成本来完成既定的生产计划,因此,如何有效的对供应链进行管理是供应链中每个企业成员关注的重点,但是近年来,随着大数据的兴起,互联网技术与各个领域的快速融合,传统的供应链模式已经无法适应快速发展的市场环境和多样化的客户需求,给供应链管理带来了新的挑战。在大数据时代下,供应链中的企业为了更好提高自己竞争优势,必须针对传统的供应链体系进行变革,在新的供应链体系中,上下游企业通过信息共享,达到互利共赢的目的,通常将制造商、经销商以及零售商等企业相结合,形成一个集生产、运作以及零售为一体的合作团体,使得整个供应链达到成本最低、效益最优。在这一过程中,需求预测是贯穿整个供应链管理必不可少的一个环节,若是无法准确的预测市场需求,在信息向供应链上流传递的过程中不断扭曲放大,将会进一步影响供应链中各个环节的协调与控制,大大削弱了整个供应链的竞争力,所以,顾客需求作为供应链管理的首要目标,在协调整个供应链中具有重要地位。准确的预测供应链的需求一直是企业生产运作面对的一个难点,因此,如何保证精确的市场需求预测是供应链管理中一项具有重要实践意义的研究问题。

在传统的供应链模式中,由于各个企业之间缺乏战略合作和信息共享,必然导致供应链中企业信息的不对称,从而大大增加了供应链中需求预测的不稳定性。同时市场需求作为供应链中企业制定生产计划的重要依据,然而当需求信息在供应链中各个成员之间传递时,由于企业之间的竞争机制以及供应链结构的影响使得需求信息很容易发生扭曲。一般来说,经过的节点企业越多,需求的误差波动也就越大,这便导致了供应链上的节点企业不能准确的把握市场需求的动态,因而各节点成员无法按照实际需求向上游发出订单。为了满足市场需求,企业只有通过扩大订购量和增加库存来保障市场供给,最后造成供应链上企业的库存大量积压,使得整个供应链的管理成本大大提高,这就是供应链管理中普遍存在的牛鞭效应现象。牛鞭效应是导致供应链运营效益低下的主要原因之一,它一直是企业管理者和研究学者研究关注的重点。牛鞭效应是供应链上一种需求变异放大的现象,它给供应链所造成的的危害是显而易见的,有时会严重威胁各个节点企业的正常运作,甚至极可能导致供应链的崩溃。由较差的需求预测而引起的牛鞭效

应，经常使得供应链中的各企业花费超额的生产成本或发生供货短缺，产生额外的制造费用、加班费，造成较高的库存水平而导致高额的库存费用和大量资金的严重浪费以及低效率的运输过程和超额的运输成本等等，这些现象都直接给供应链的运营效益带来了负面影响，不仅大大降低了供应链上各企业的生产效率，而且严重损害了供应链的市场竞争力。

牛鞭效应是制约供应链发展的重要因素，自从发现牛鞭效应以来，多年来一直受到企业家和学者的高度关注，在较初的研究中，主要集中在认识牛鞭效应现象以及证明其存在的一个过程；随着对牛鞭效应的深入认识，学者们开始转入对其进行量化研究，并在此基础上探讨牛鞭效应的成因，分析供应链中各个因素对牛鞭效应的影响程度，随后针对相应的影响因素进一步提出缓解牛鞭效应的措施和方法。需求预测是供应链中不可或缺的一个环节，也是影响牛鞭效应的一个重要因素，一个准确的需求预测是削弱牛鞭效应的重要手段，因此，在供应链管理中研究分析需求预测与牛鞭效应的关系，以及如何提高预测的精确度来缓解牛鞭效应一直是该领域的研究热点，同时也是供应链管理中急需解决的问题。

1.2 本文研究目的与意义

1.2.1 本文的研究目的

供应链管理是对供应链系统上每个企业成员在生产运作方面进行有效的协调和控制，以达到供应链整体效益最优。一个有效的供应链管理对于供应链上各个节点企业在生产运作的过程中起着至关重要的作用。高效的管理不仅能全面提升企业的生产效率提高自己的核心竞争力，而且能够大大的缓解牛鞭效应从而达到降低供应链整体运营成本的最终目的。然而，由于日新月异的社会经济，瞬息万变的顾客需求以及不断加剧的市场竞争等，这些日益变化的复杂环境增加了供应链管理中面临的不确定性。为此改善供应链管理适应当前多变的市场环境对于供应链自身发展具有非常迫切非常重大的意义。

在实施供应链管理的过程中，供应链中上游企业根据下游企业的订单量或需求量制定生产计划，然而由于各企业的竞争机制缺乏信息共享，不可避免的使最下游的需求信息随着供应链逐级的传递被逐渐的放大，从而导致牛鞭效应的产生。然而，一直以来许多制造企业所面临的产品需求波动很大，从而导致企业的生产量常常大于市场需求，造成库存的大量积压，这种现象在很多制造企业中经常发生，它给企业和供应链带来了非常大的负面影响，不仅造成供应链整体运作效率低下，而且大大增加了供应链中各个成员的成本费用，严重影响企业的生产效益。研究发现，牛鞭效应已经成为供应链管理中一个普遍存在且难以消除的重要问题。因此，牛鞭效应一直是供应链管理研究的核心。需求预测作为供应链管理的起点，是供应链管理尤为关键的一环，也是影响牛鞭效应的

重要因素之一，精确的需求预测是缓解牛鞭效应的重要保障。所以，如何在供应链各个成员之间实现资源共享，利用共享后的各类复杂数据实现精确的预测，准确把握供应链中其他不可控的因素对预测带来的影响，降低需求预测的误差，缓解牛鞭效应，改善供应链性能，提高企业运作效率已成为供应链管理工作的重中之重。

国内外学者对供应链需求预测已经进行了广泛深入的研究，取得了显著的研究成果。在以往的供应链需求预测研究中，大多数都是通过以往的历史需求数据采用较为简单的统计学方法进行预测分析，是在假定供应链需求是一种线性变化的基础上建立预测模型，忽略了供应链需求的非线性、不确定性等变化特点。事实上，市场需求往往受到多个因素的影响，因此，传统的预测方法无法很好地掌握供应链需求的变化规律。近年来随着各种新兴网络技术的日新月异，大数据技术的崛起，各类需求数据更加容易收集获取，同时数据来源以及种类也变得越来越复杂，传统的数据预测方法在面对高速多样化的数据时显得愈加的难以适从。大数据作为一种新兴理论，对数据预测有着极其重要的作用，基于此，大量的国内外学者和研究所纷纷围绕大数据理论展开讨论与研究，同时也有部分企业将其应用于企业的管理运营。从已收集的文献资料来看，对供应链需求预测以及牛鞭效应的研究虽较为广泛，但在大数据的背景下展开的研究目前还很少涉及，因此，利用大数据分析提高需求预测精度，降低牛鞭效应是目前非常前沿的一个研究课题。鉴于此，本文通过查阅相关文献资料，在大数据背景下构建供应链系统，利用人工智能算法将影响市场需求的各个因素与供应链的需求预测建立起联系，进一步分析在大数据背景下的需求预测对牛鞭效应的削弱缓解作用，通过分析所得出的结论，提出相应的供应链管理方法和措施，从而更好的指导供应链上企业的生产运作管理，提高供应链整体的运作效率。

1.2.2 本文的研究意义

随着互联网技术与生产技术的不断发展，企业面临的社会经济环境与市场需求出现新的态势，企业之间的竞争日益剧烈，近年来，大数据理论的出现和不断成熟，为供应链管理和企业的发展带来了巨大机遇和挑战。加深对考虑大数据背景下的供应链需求预测及其对牛鞭效应的影响的研究，对于适应新的市场需要的变化、提高企业市场核心竞争力、实现供应链整体效益最优具有深刻的理论与实践意义。

理论意义：根据前人研究的成果，发现前人在该领域或相关领域都有所提及但未做深入的研究分析，尤其是在我国对大数据在供应链中的研究只是处于一个起始阶段。因此，在大数据的背景下对供应链的需求预测及牛鞭效应现象进行研究，为降低需求预测误差和缓解牛鞭效应提供了新的思路、手段和方法。在大数据环境下构造一个新的供应链模型，从需求预测的角度深入分析大数据背景下供应链中牛鞭效应的大小，在数据预测的过程中区别于传统单一变量的线性预测模型，考虑供应链中其他因素给需求带来的

各种影响以及市场需求在供应链中非线性变化的特点,采用数据挖掘以及人工智能算法构建多变量的非线性需求预测模型,从而实现较为精确的需求预测,然后根据相应的预测结果对牛鞭效应进行量化,最后提出见解和相关结论。在一定程度上弥补了国内外关于在大数据背景下供应链的需求预测及牛鞭效应研究分析的理论空缺,为之后的研究方向扩展新的思路,对供应链的需求预测与牛鞭效应的研究具有十分长远的理论意义。

实践意义:供应链牛鞭效应的分析及治理对供应链中各个成员来说至关重要,而一个准确的需求预测是控制牛鞭效应的重要因素。在如今数据来源众多、种类繁杂的环境中,大数据是处理数据的重要手段,因此在大数据的环境下分析解决供应链管理中的各种问题具有重大的现实意义。而采用基于大数据背景下的需求预测来实现供应链中企业需求订单的准确化是缓解牛鞭效应提高供应链运作效率的重要途径和手段,特别是针对每个供应链成员来说,在该方法下实现精准预测,有利于减少供应链上节点企业的库存积压,改善各企业的生产计划。从这个角度来说有效的降低了供应链整体成本,提高了各企业的运作效率。因此,对在大数据背景下的供应链需求预测与牛鞭效应的分析,是一项具有重要现实意义的研究。

1.3 国内外研究现状

1.3.1 供应链牛鞭效应的研究现状

首先对供应链牛鞭效应现象进行描述的是 Forrester(1961)^[1],之后 J D Sterman(1989)^[2]和 D R Towill(1996)^[3]等人也对此现象进行分析研究。Kalm(1987), Sterman(1989), Lee(1997), Chen(2000)^[7]等人分别从论证牛鞭效应的存在性、牛鞭效应的成因以及缓解牛鞭效应的方法这三个方面对供应链牛鞭效应现象进行了详细的讨论。

Kahn(1987)^[4]对供应周期内如何明确企业的计划生产量进行了分析,研究发现需求信息在供应链传递过程中不断放大从而导致生产量远远大于市场需求量。Sterman(1995)^[5]利用“啤酒分销游戏”的实验证明了牛鞭效应的存在并对牛鞭效应现象进行了具体的分析。Lee(1997)^[6]则从供应链的运作角度研究分析产生牛鞭效应的原因,最终得出了以下四个主要原因:第一,供应链上各个节点对需求信息的处理加工;第二,供应量无法满足需求时出现限量配给状况,使得供应链企业之间不断地短缺博弈;第三,零售商分批订货方式;第四,生产商品的价格波动。

Towil(1991)^[8]对牛鞭效应进行模拟研究并对其展开了实证分析。研究表明:需求信息在供应链上不断传递的过程中逐渐被放大,传递的次数越多,波动就越大,当需求信息到达供应链顶端时,需求信息的放大幅度高达8倍有余。

Metters R(1997)^[9]通过设定需求分布函数推导出最优成本函数,然后采用启发式算法对供应链中每个环节的牛鞭效应进行量化分析。

Frank Chen(2000)^[7]等人在 Metters R 研究的基础上,通过构建了一个只有一个供

应商和零售商的两级供应链模型，然后利用供应商与零售商之间的需求方差之比来衡量牛鞭效应。这个表达式很形象地描述出牛鞭效应的不确定性本质，较科学地对牛鞭效应进行了量化。

Metter (1997)^[9]通过对供应链牛鞭效应的量化研究分析牛鞭效应给供应链带来的危害，结果表明，消除牛鞭效应可以有效地提高供应链的效益。Akhtar Tanweer (2014)^[10]采用非线性规划从供应链整体所消耗的成本来量化牛鞭效应，并且用遗传算法选择最合适订单策略缓解牛鞭效应。

Xu (2001)^[11]等人在建立预测模型的基础上，使供应链上各节点企业同时进行需求预测，并根据独立的预测结果向供应链上游发出订单，结果表明，信息共享是缓解牛鞭效应的有效手段，在信息共享下需求预测也能得到更好的保障。

Yu (2001)^[12]等在一个简单的两级供应链模型的基础上研究了不同类别的信息共享条件下的牛鞭效应的强弱。

Erik Hofmann (2015)^[13]从理论出发，在系统动力学的基础上构建供应链模型，利用传递函数将大数据的 Variety、Volume 和 Velocity 三个属性引入模型当中，分别分析了这三个属性对牛鞭效应的影响，结果发现，大数据的高速率特性可以消除供应链中的牛鞭效应，这一发现为我们研究应用大数据缓解牛鞭效应提供了理论基础。

邵晓峰 (2001)^[14]认为，供应链的固有属性是产生牛鞭效应不可忽视的因素，同时他通过举例说明了当供应链节点成员在信息不充分的条件下，追求自我化决策时，供应链就会产生牛鞭效应。

傅烨，郑绍濂 (2002)^[15]引入委托代理理论来分析供应链中的牛鞭效应，得出供应链的组织结构是产生牛鞭效应影响供应链运作效率的根本原因。

达庆利 (2003)^[16]分析了缓解牛鞭效应的方法，例如：有效协调供应链各节点企业、签订适当的合约、构造完整的激励和监督体系以及实现成员间的信息共享等措施都可以对牛鞭效应起到缓解甚至消除的作用。同时给出了具体的实施操作。

万杰，寇纪淞 (2003)^[17]在系统论的基础上，从供应链结构出发对供应链中的牛鞭效应进行分析，根据分析提出三种标准的供应链组织结构，并分析可在不同供应链结构下牛鞭效应的大小。

刘思峰，李翀 (2013)^[18]首先根据供应链库存状态的内部系统动力学机制，建立状态转移模型，在考虑时滞因素的情况下，对供应链牛鞭效应进行了描述分析，并通过研究结论提出一种新的库存策略，利用计算机仿真验证了该策略对牛鞭效应具有良好的抑制作用。

刘红，王平 (2007)^[19]以 AR(1)自相关模型模拟市场需求变化，在采用订货点库存策略的条件下，分别推导出了零售商采用移动平均法、一次指数平滑法预测及均方误差优化进行市场需求预测时供应链中牛鞭效应的量化公式，并通过计算机软件对三种预测

方法下牛鞭效应进行仿真验证,讨论了不同预测技术对供应链牛鞭效应的影响程度及其适用范围。

通过对文献总结分析发现,国内外对牛鞭效应的研究主要集中在牛鞭效应存在性的证明、牛鞭效应的成因与量化以及缓解牛鞭效应的措施方法这三个方面。在对牛鞭效应刚开始的研究阶段,主要集中在对供应链中牛鞭效应的认识以及对证明其存在的一个过程,并分析形成牛鞭效应的主要原因。随着对牛鞭效应问题深入认识,学者们开始转入对牛鞭效应的量化研究,考虑使用统计学方法和系统工程方法来量化牛鞭效应。目前牛鞭效应问题的最新研究方向则是考虑通过控制影响牛鞭效应的主要原因,如需求预测,供应链结构、价格波动等,来削弱供应链牛鞭效应。本文就是通过研究需求预测来实现缓解牛鞭效应的目的。

1.3.2 需求预测的研究现状

需求预测作为供应链中企业生产运作的重要依据,已经逐步成为驱动整个供应链发展的核心力量。一个精确的需求预测对于保障供应链的健康运营具有至关重要的作用。需求预测是企业给出了其产品在未来一段时间内的需求期望水平,它能够给企业制定中长期计划提供重要事实依据,来指导企业作出下一阶段的决策。然而,由于供应链自身的局限性、市场需求的不确定性,以及现有算法本身存在的一些问题,造成了较大的需求预测误差,大大增加了预测的难度。近年来,大量学者和科研机构对供应链需求预测进行了广泛、深入的研究,提出了许多的需求预测模型,取得了相应的研究成果。

国外对于科学的需求预测的研究起步较早,随后我国学者也做了相应的研究,目前很多预测模型已经广泛的应用到企业中。王惠文,孟洁(2007)^[39]根据历史样本数据构建了多元线性回归预测模型;刘红,王平(2007)^[19]总结了基于统计学时间序列分析的线性预测法,包括移动平均法、指数平滑预测法以及均方误差法,并比较了在三种预测方法下的牛鞭效应;代亮,许宏科等人(2014)^[34]提出了基于 MapReduce 的并行多元线性回归模型;卢阳(2017)^[31]构建了一种少数据建模的灰色线性回归组合金融预测模型;黄邦菊,林俊松等(2013)^[35]通过选取影响机场旅客吞吐量可能因素,分析各影响因素与旅客吞吐量之间的相关性,建立机场旅客吞吐量的多元线性回归预测模型预测未来时刻机场的旅客量。

通过文献回顾可以发现,在传统的供应链需求预测研究中,主要预测模型有时间序列、多元线性回归等模型,这些传统的预测方法都是在假设供应链需求是一种线性变化趋势的基础上对下一阶段的供应链需求进行预测,其操作简单、容易实现,但预测精度往往达不到实际要求。事实上供应链需求变化十分复杂,具有不确定性、非线性等变化特点,因此传统的预测方法不能很好的预测供应链的需求变化规律,在企业的实际应用价值不高。

随着数据挖掘和机器学习语言等相关理论的不断成熟,部分学者提出了基于人工智能的供应链需求预测算法。如 Hu Y (2017)^[23]提出了一种基于遗传算法的灰色预测模型来进一步提高 G (1,1) 模型的预测精度; Liu Y 和 Ju W (2016)^[25]等利用人工蜂群算法优化全生命周期需求预测模型中多项式参数的拟合来实现高精度的预测效果; Adamowski (2008)^[31]和 Wang G (2013)^[32]通过利用神经网络算法构建预测模型,章杰宽,朱普选 (2013)^[43]提出了将灰色神经网络进行数学建模,在标准粒子群算法基础上构建一种动态粒子群预测算法;孙涵,杨普容 (2011)^[38]提出了支持向量回归机预测模型,并在 Matlab 上通过对能源需求预测验证了该模型的预测性能; Noori(2015)^[26]通过支持向量计算法构建在线 5 天需氧量的预测模型,降低预测过程中的不确定性, Cao J 和 Jiang Z 等(2017)^[28]引入免疫粒子群算法改进支持向量机预测模型中的参数选择,提高预测精度;顾嘉运,刘晋飞 (2014)^[44]结合支持向量机分类与回归算法提出一种大样本数据分类回归预测改进算法。这些算法模型具有优异的推广能力,能较好的处理非线性预测问题,一定程度上提高了供应链需求预测的精确性,但是大部分需求算法模型主要针对单变量时间序列进行建模与预测,忽略了供应链中其他因素对预测对象的影响,仅仅通过历史数据寻求某单一变量的变化规律获得下一阶段的预测值。然而,在实际的供应链生产运作中,某一产品的需求往往受到多个变量的影响,当其他变量的影响无法忽略时,采用单变量的时间序列预测模型对需求进行预测很难获得理想的结果。近些年来,部分学者提出了多变量预测模型,在充分考虑影响需求预测的各个因素的基础上进行预测,如陈果,杨虞微 (2007)^[39]提出了 BP 神经网络的多变量预测模型;宋士豹,杨淑莹 (2018)^[35]提出了一种基于临近相点聚类分析的多变量局域多步预测模型;丁松,党耀国等 (2017)^[42]提出了驱动因素控制的 DFCGM (1,N) 模型及其拓展模型,这些模型准确的分析了预测结果与其他影响因素之间的相关关系,改善了整体的预测效果。

1.4 本文的研究内容及创新点

1.4.1 本文的研究内容

本论文各章节的主要研究内容如下:

第一章为绪论部分。主要阐述了论文课题的选题背景、研究目的和理论实践意义,对供应链需求预测和牛鞭效应的相应文献进行了综述和评价,并分析总结了相关内容在国内外的研究现状。最后简要说明了论文的主要研究内容及其创新点。

第二章主要就论文所涉及到的理论基础进行了论述,首先,对大数据与云计算进行了综合概述,然后,对供应链和供应链管理的相关知识进行了阐述。最后,介绍了目前供应链中常用的传统需求预测方法和基于机器学习和人工智能算法的预测模型;并给出了牛鞭效应的定义、危害成因以及计量方法,为下面的研究提供了理论支撑。

第三章在 Multi-Agent 系统的基础上建立了大数据背景下的供应链模型。首先通过

分析大数据环境下供应链的特点，架构基于大数据的供应链体系结构；然后通过引入 Agent 原理和 Multi-Agent 系统来解决供应链成员之间信息共享问题以及提高供应链对分布式环境的适应能力；最后在以上的研究基础上提出大数据背景下基于 Multi-Agent 系统的供应链模型。

第四章提出了基于遗传算法的支持向量机预测模型，首先介绍了一般的传统支持向量机模型，讨论模型中参数对拟合预测的影响。然后在此基础上提出利用遗传算法对原有模型的参数进行优化改进，构造基于遗传算法的支持向量机预测模型。最后通过对某电子产品的销售进行拟合预测验证了新模型的预测性能。

第五章采用信息熵理论选取主要特征因素，考虑了多个变量的相互影响，提出了基于多变量支持向量机的需求预测方法，实现了多变量预测，并在多变量的支持向量机预测基础上引入 BP 神经网络来减少预测误差，提高模型对数据的拟合精度，最后过计算机模拟仿真进行需求预测和牛鞭效应的分析。

1.4.2 本文的创新点

本文根据大数据背景下供应链所具备的新的特点构建了一类基于大数据背景下的供应链模型，主要研究了供应链的需求预测并在此基础上分析了需求预测对牛鞭效应的影响。文章的创新点主要有以下两点：

1、方法上的创新。以往的学者研究供应链需求预测时采用的多是单变量线性预测模型，但是实际情况是供应链的需求不仅呈现不确定性、非线性的变化趋势，而且同时受到其他多个因素的影响。为了充分考虑影响市场需求的各个影响因子以及需求变化的自身特点，本文采用多级 Agent 系统构造供应链模型，利用信息熵来选取对需求影响程度较高的影响因子，并在此基础上提出一种基于多变量支持向量机回归算法的供应链需求预测模型，实现降低需求预测误差的目标。

2、应用上的创新。将大数据理论与供应链管理相结合，在大数据的背景下讨论供应链的需求预测与牛鞭效应。本文根据大数据的特点，构造新的供应链结构体系，描述供应链中信息处理规则，并在大数据的环境下构建供应链的需求预测模型，结合新的需求预测算法对供应链需求进行预测，并分析了在该预测算法下的牛鞭效应的大小。

第2章 相关理论基础

近年来,以物联网、移动互联网、云计算和大数据为代表的新一代信息科技发展迅猛,而大数据则风头最劲。大数据的快速崛起使得企业获取信息的手段更加高效丰富,为供应链的构建以及需求预测提供了新的方法。因此,本章主要介绍了大数据,供应链与供应链管理等相关理论知识,同时对供应链需求预测和牛鞭效应相关知识的进行详细阐述,以上理论知识为后续章节的研究奠定了基础。

2.1 大数据概述

大数据一词正式出现是在2011年麦肯锡全球研究院发布的《大数据:下一个创新、竞争和生产力的前沿》研究报告中。数据挖掘理论和数据库技术的日趋成熟,给大数据的研究奠定了良好理论基础。时至今日,大数据不断地向各个领域渗透,已经广泛的应用于互联网、金融、教育等各个行业。而对于大数据的定义也非常广泛。其中麦肯锡全球研究所给出的定义,是目前为止最为全面的:大数据是指一种规模大到无法在规定时间内用现有的常规软件工具对其内容进行获取、存储、管理和分析的数据集合。

大数据具有海量的数据规模(volume)、多样的数据类型(variety)、快速的数据流转(velocity)和数据蕴藏价值大(value)四大特征。

数据量大(volume)指的是数据的采集、存储和计算的量都非常大。造成数据量增大的原因有很多,如移动设备和传感器的使用,基于互联网社会化网络应用的发展等等。数据的大小决定所考虑的数据中蕴藏的价值。

数据种类多(variety)是指数据的种类和来源较多,如多种传感器、智能设备、社交网络等。数据的种类包括结构化、半结构化和非结构化数据,包括图片、音频、视频、季节、地理位置等多类型数据。

数据的增长及处理速度快(velocity)指数据每分每秒都在爆炸性地增长,而对数据的处理要求也很高,数据的快速动态的变化使得流式数据成为大数据的重要特征,对大数据的处理要求具有较强的时效性,能够实时地查询、分析、推荐等。

数据的价值大(value)是指在海量的数据中,存在着巨大的被挖掘的有价值的信息,然而由于数据总量的不断增加,数据单位价值密度却相对较低,如何通过数据挖掘算法,合理的运用大数据,以低成本创造高价值是大数据要解决的重要问题。

整个大数据的处理流程可以定义为:在合适工具的辅助下,对广泛异构的数据源进行抽取和集成,结果按照一定的标准进行统一存储,并利用合适的数据分析技术对存储的数据进行分析,从中提取有益的知识并利用恰当的方式将结果展现给终端用户。具体来说,从数据源到数据的最终应用,其中的处理流程可以分为数据抽取与整合、数据分

析、数据可视化。大数据的处理流程如图 2.1 所示。

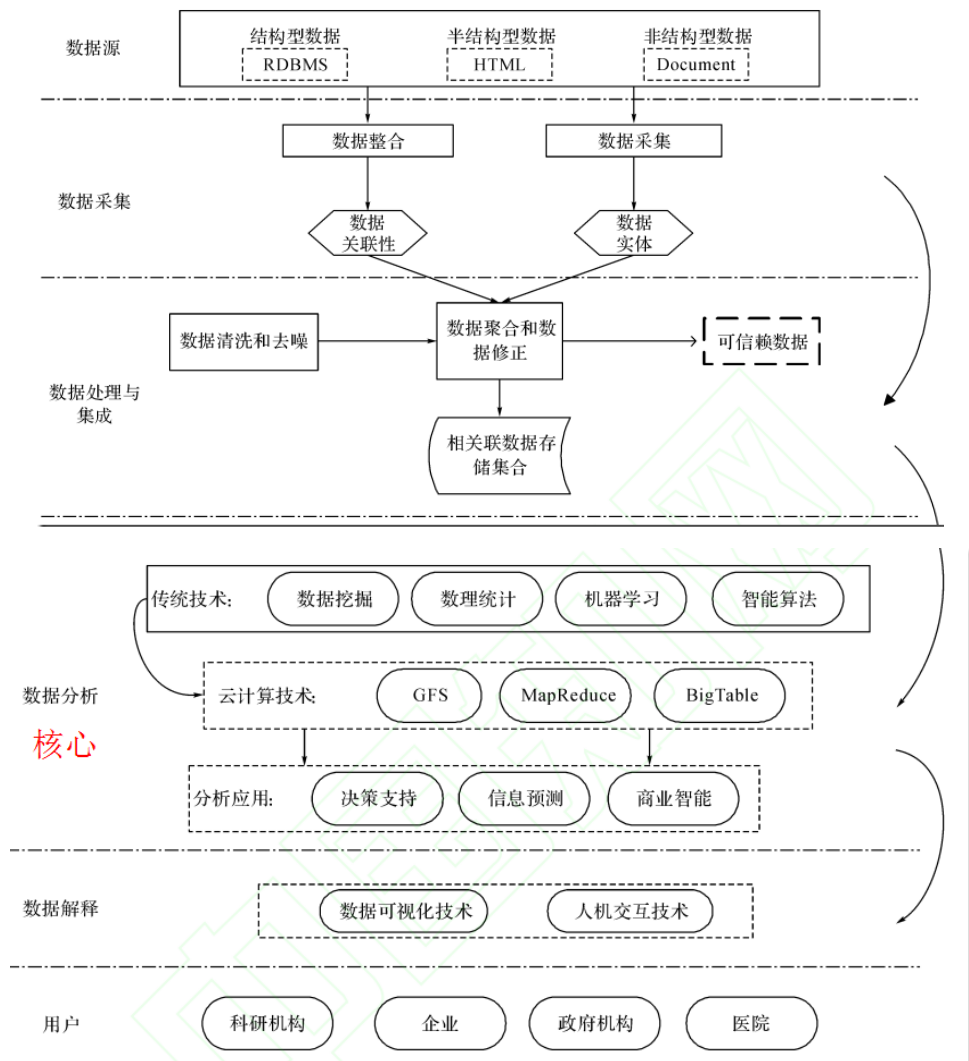


图 2.1 大数据的处理流程图

从技术上看，大数据与云计算的关系就像一枚硬币的正反面一样密不可分。大数据必然无法用单台的计算机进行处理，必须采用分布式架构。它的特色在于对海量数据进行分布式数据挖掘。但它必须依托云计算的分布式处理、分布式数据库和云存储、虚拟化技术。云计算是一种可以调用虚拟化的共享资源池的计算模型，这些资源池可以根据负载动态重新配置，以最小化的管理工作量快速开通和释放资源，以达到最优化使用的目的。

一般来说，数据的存储与计算是计算机的主要功能，而硬件、操作系统和应用程序是计算机的主要结构，这三部分互相协调控制，使得计算机正常运转。虚拟化是云计算的核心思想，即利用虚拟的互联网技术将一些地理位置不同，逻辑空间不相关的多台传

统计算机整合起来，虚拟成一个云服务平台。将这些连接在一起的计算机收集的资源融合为资源共享池，使得运算和存储能力都得到相应的扩大，同时采用与单个处理机模式相似的管理模式进行管理。不同于传统的计算机工作方式，云计算采用的是一种面向服务的体现架构来为用户提供各项所需服务。随着大数据技术的不断成熟，云计算的应用领域更加全面广泛。

2.2 供应链与供应链管理

2.2.1 供应链

供应链是在物流思想的基础上发展起来，目前，国内外并未对供应链进行统一界定，根据供应链的发展阶段，大致可以分为以下三种定义，并且在相应的阶段供应链自身具有各自鲜明的特点和不同的关注焦点，如表 2.1 所示。

表 2.1 不同阶段供应链的定义、特点和关注焦点

发展阶段	供应链定义	特点	关注焦点
注重物流管理阶段	供应链是把购买的原材料通过生产加工和销售等活动转移到用户的一个过程。	供应链结构非常单一，与供应链中的成员联系不紧密，甚至可能存在冲突。	企业自身的生产和利益。
注重价值增值链的阶段	将供应链定义为产品在生产和运输过程中由供应商、生产商、零售商以及消费者组成的供需网络。	供应链形成较完整的体系，供应链上的各个节点相对协调。	产品的价值增值，成本节约，供应链上节点企业的相互协调。
注重“网链”的阶段	围绕核心企业，通过对信息流、物流、资金流的控制，在产品生产及流通中将涉及的上游和下游企业以及最终用户连成一体的功能网链结构模式。	结构复杂 节点联系紧密 形成核心节点。	快速反应市场变化的供应链战略架构，供应链的整体效益和竞争力。

通过上述的总结我们可以发现，时至今日，供应链已经得到了飞速的发展。简单的来说，供应链是一个由供应商、制造商、分销商、零售商、顾客等成员组成的网络。一般的供应链如图 2.2 所示。且具有以下几点特征：

（1）复杂性。由于供应链是由多个的企业组成，而这些企业通常是不同等级不同

类别的，所以供应链的结构模式往往比一些独立企业的结构更加复杂。

（2）动态性。由于企业战略和市场需求的变化导致供应链中节点企业需要动态地更新，这就使得供应链具有较强的动态性。

（3）面向用户的需求。供应链都是在市场需求的基础上形成、存在以及重构，顾客的需求是驱动供应链信息流、物流和资金流运作的重要力量。

（4）交叉性。节点企业可以是多个供应链的成员，多个供应链相互交叉，给供应链的协调管理增加了难度。

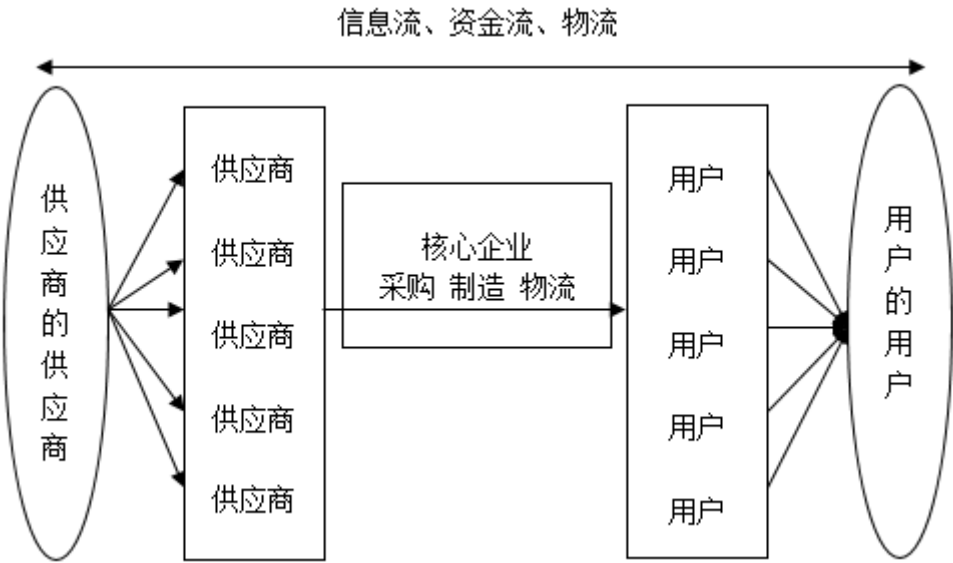


图 2.2 供应链流程图

2.2.2 供应链管理

供应链管理是指使供应链运作达到最优化，以最少成本，令供应链从采购开始，到满足最终客户的所有过程。在这个过程中有效地把供应商、制造商、物流和零售商联系起来生产销售产品，并在准确的时间内把正确的产品运输到指定的地点，来满足顾客的需求，同时实现供应链成员共同获利的目标。具体的供应链管理流程如图 2.3 所示。

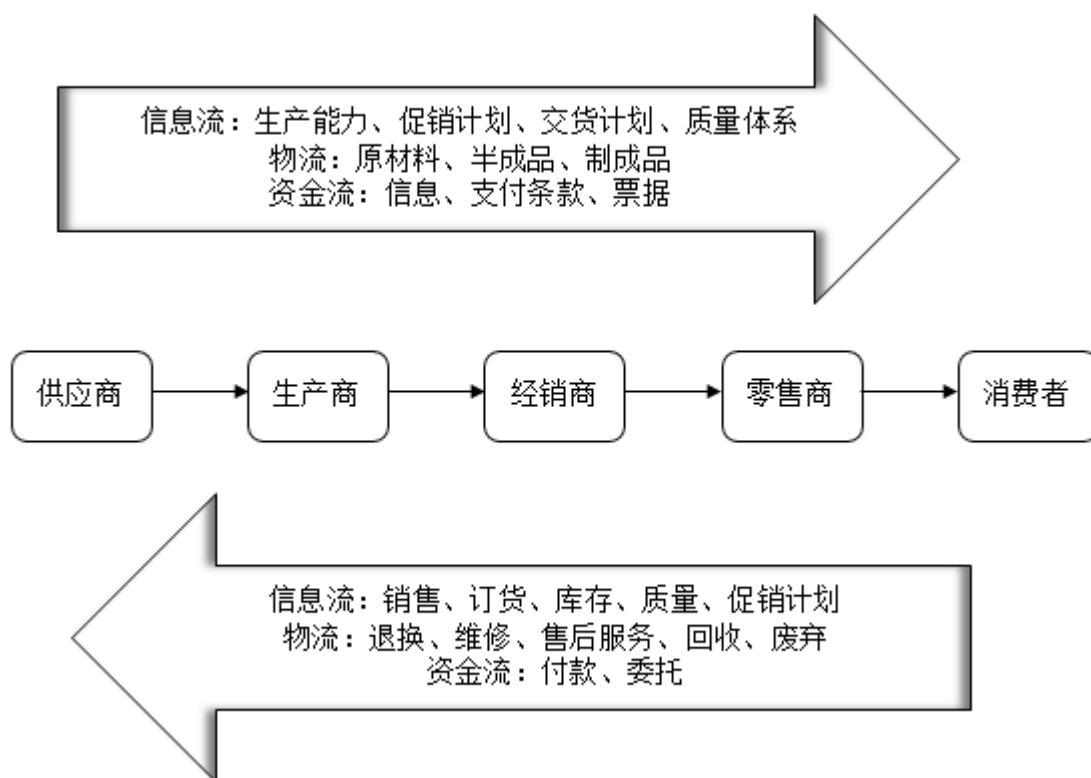


图 2.3 供应链管理的流程

从供应链管理的流程图可以发现，所谓供应链管理其实就是在供应链中有效控制各种流的决策方法，是对供应链中每个节点成员的信息流、物流以及资金流进行规划、协调和控制。供应链管理的目的是通过优化改善所有相关过程，提高供应链整体竞争力和对市场需求的适应能力。其主要内容包括：供应链系统设计；市场需求预测；生产计划与管理；客户服务与物流管理，信息流和资金流的管理等。

供应链管理的主要目标是提升整个供应链的运作效率降低整体成本，所以供应链管理具有高度的系统思想、合作思想和集优性思想。其中系统思想是指供应链管理将供应商、制造商、零售商以及消费者看作一个有机联系的整体，建立统一的运营目标，对所有成员进行协调控制从而达到共赢的目的。合作思想是指供应链管理是在合作共赢的基础上进行的。供应链中各成员由传统的竞争性关系转变为战略合作关系，它将市场需求转化为所有节点企业的集体活动，每个企业在生产或销售活动中相互协调实现整体利益的最大化。集优性思想是指供应链管理是将具有一定市场竞争力和特长的企业集中共同创造价值的活动，以强强联合的原则选择节点企业，通过聚集整合各个节点企业的资源和能力，发挥整体效能，将单一企业的核心竞争力整合为供应链的整体竞争力，从而大大的提高了供应链的竞争优势。

2.3 需求预测与牛鞭效应

2.3.1 供应链中的需求预测

为了适应市场的多变性，企业必须随时掌握最新的市场需求变化规律，了解供应链的需求信息，因此需求预测是供应链管理中必不可少的一环，是供应链中所有节点企业制定生产计划、销售策略等其他活动的基础。简单来说，需求预测是估计未来一定时间内整个产品的需求量。目前，从预测方式上可以将需求预测方法分为两大类定性预测和定量预测。

定性预测是通过经验判断或调查分析对未来的某一事物做出的定性评估的方法。这种预测方法只需要少量数据的带入，结合大量的市场调查加以专家经验的辅助来实现预测的目的，是一种直观、简单、易操作的方法。然而由于缺少数据的缘故，定性分析带有很强的片面性和经验主义，可能导致预测结果出现巨大的偏差，很难适用于影响因素复杂的情况。该类方法主要在缺少预测对象历史数据是采用，常用的定性预测方法主要包括：德尔菲法、头脑风暴法、专家意见法和销售人员意见集中法等

定量预测是在收集足够数量或比较完备的数据统计资料的基础上，运用数学方法构建合适的预测模型，利用历史数据资料对未来需求进行预测。主要包括时间序列法和因果关系分析法。其中时间序列模型是按照时间的先后顺序对预测值进行排序形成序列，通过历史数据来预测下一时期的需求。主要模型包括移动平均法、指数平滑法、均方误差法、时间序列分解等。因果分析预测法主要用于预测对象的变化取决于某些相关变量时的预测。主要模型有：一元回归预测、多元回归预测、投入产出模型和生命周期模型等。图 2.4 是对供应链常见需求预测方法的总结。

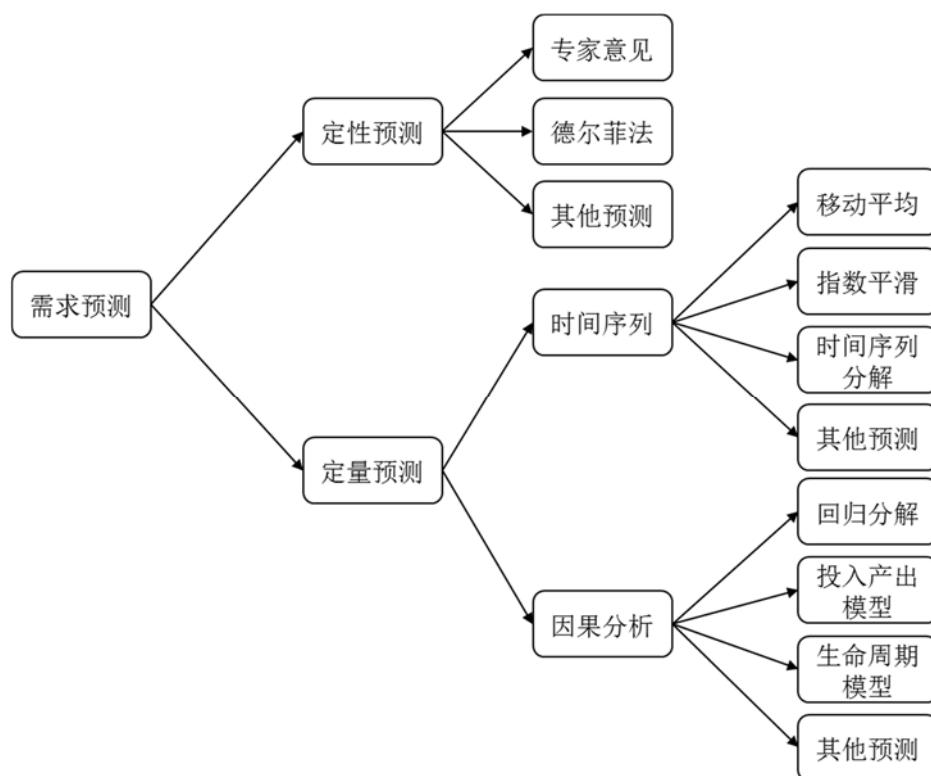


图 2.4 供应链需求预测常用方法

随着供应链的不断发展成熟，供应链结构越来越复杂，影响供应链需求的因素更是越来越多，使得市场的需求具有不确定性、非线性等变化特点。在这种纷繁复杂的社会环境中，传统的预测方法已经无法准确的刻画供应链需求的变化规律，因而在企业的实际生产运作中应用价值不高。由于统计学的迅速崛起，基于统计学思想的机器算法和人工智能算法不断的被用于供应链需求预测当中。其中主要包括模糊集方法、遗传算法、神经网络算法和支持向量机算法等。表 2.2 对这几类算法的基本原理和特点进行了简单的归纳和叙述。

表 2.2 基于统计学思想的机器算法

算法	算法概述
遗传算法	是模拟自然界生物进化机制的一种人工智能算法，通过选择、交叉、变异的进化过程来随机搜索最优解，在优化求解时不受连续性的影响，并且对先验知识要求不高。
神经网络算法	模仿动物神经网络行为特征，进行分布式并行信息处理的算法。具有良好的自适应性和自组织性特点。
支持向量机	该方法在处理非线性高维数据具有较好效果，同时具有很强的泛化能力。在供应链需求预测问题上具有十分明显的优势，在一定程度上提高了需求预测的准确性。

2.3.2 供应链中的牛鞭效应

牛鞭效应是供应链管理中普遍存在的问题，它是指需求信息在供应链自下而上的传递过程中发生扭曲放大的现象。它给供应链的带来的危害主要有以下几个方面：（1）需求信息的扭曲容易造成市场需求增加的错觉，导致超额库存的积压；（2）市场需求过度的变化增加了企业生产计划的不确定性，企业不得不频繁的调整生产计划，导致额外成本支出的增加；（3）不能及时的满足客户的有效需求，降低供应链的服务水平；（4）给供应链中各个成员的合作带了负面影响，增加了管理的难度。这一系列的问题都大大降低了供应链的运作效率和整体竞争力，甚至可能导致整个供应链崩溃。

产生牛鞭效应的原因有很多，国内外学者针对此问题开展了深入的研究，根据大量研究结果发现导致牛鞭效应的原因主要有：（1）供应链各节点企业所采用的需求预测方法；（2）短缺博弈和限量供应；（3）产品价格波动以及批量订货方式；（4）供应链信息共享程度。根据牛鞭效应产生的原因，可采用订单方差与需求方差比来对牛鞭效应进行量化，具体公式定义如下：

$$BWE = \frac{\text{订单波动方差}}{\text{需求波动方差}} = \frac{Var(q_t)}{Var(D_t)} \quad (2.1)$$

其中， q_t 表示订单量， D_t 表示实际的需求量， $Var(q_t)$ 表示订单量波动的方差值， $Var(D_t)$ 表示需求量波动的方差值；该表达式形象的描述了牛鞭效应的不确定性和严重程度，要想完全消除牛鞭效应在实际操作中很难实现，只有当 $BWE=1$ 时，表示需求信息在传递过程中没有发生失真现象， BWE 的值与 1 的距离越大，牛鞭效应也就越严重。由此可以看出，需求预测是影响牛鞭效应的一个关键因素，不同的预测方法会产生不同程度的牛鞭效应，预测越精确，订单波动越小，牛鞭效应就越弱。所以，通过优化需求预测方法，可以大大的缓解供应链牛鞭效应。

2.4 本章小结

本章节的主要任务是介绍论文研究所涉及的相关理论基础。首先，对大数据与云计算进行了综合概述，总结了大数据的特点和云计算的体系架构。然后，对供应链和供应链管理的相关知识进行了阐述。最后，介绍了目前供应链中常用的传统需求预测方法和基于机器学习和人工智能算法的预测模型；并给出了牛鞭效应的定义、危害成因以及计量方法，形象的说明了需求预测对牛鞭效应的影响，为下面的研究提供理论支撑。

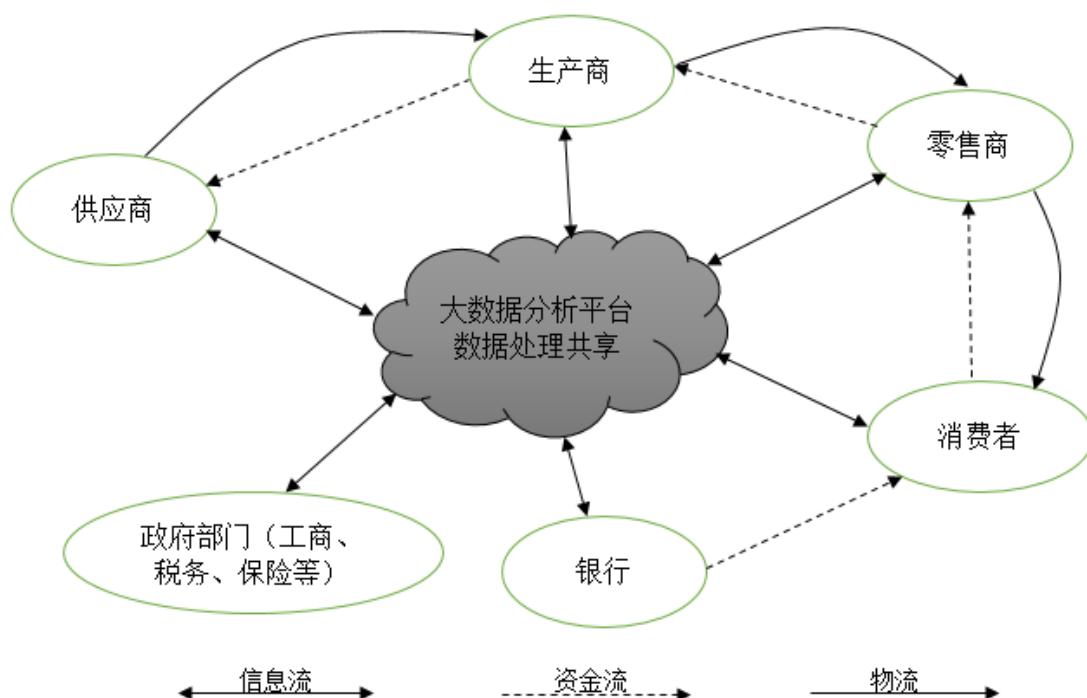
第3章 大数据背景下基于 Multi-Agent 系统的供应链模型

供应链管理主要是通过对供应链中每个成员进行组织、协调和控制,达到以最小的成本获取最优供应链效益的目的,全面提升供应链的整体竞争力。传统的供应链由于缺乏信息共享,需求预测存在较大的误差,很容易造成牛鞭效应,给供应链的正常运营带了巨大的恶劣影响。大数据的出现,使得数据收集越来越容易,同时也给数据的存储和计算提供了平台。在大数据背景下供应链各节点企业很好的实现了信息的共享。本章节在云计算的基础上对供应链体系进行架构,然后根据大数据背景下供应链的特点,利用多级 agent 系统抽象模拟大数据服务平台下的供应链系统,构建大数据背景下基于多 agent 系统的供应链模型。

3.1 基于大数据的供应链体系架构

传统的供应链中各个企业之间缺乏信息交流和共享,供应链上的每个成员往往只能获得相邻企业的相关数据,增大了需求预测产生的误差,导致牛鞭效应。云计算和大数据技术的发展,使架构分布式供应链体系成为可能,这种分布式供应链体系允许供应链各个成员在信息交互和信息共享的基础上进行快速的数据分析处理。大数据分析平台是构建这类供应链的核心,供应链中成员通过该平台获取各种各样的服务,比如数据存储、数据分析、软件计算等。这些服务使得企业具备了快速完成信息化建设的能力,同时为供应链的架构提供了充分的信息基础和保障。

基于大数据的供应链体系架构,是将供应链上各个企业看做不同的网络节点,以大数据分析平台为中心,形成一个功能一体化的供应链网络体系。在这种大数据供应链框架中,大数据分析平台是联系各个节点的中介,实现供应链中各个节点企业以及相关部分之间的数据交流,将涉及的每个企业的资源整合在一起,在供应链中进行共享。供应链中节点企业通过平台提供的各种服务获取共享资源,并且每个成员在供应链中具有平行地位,在这里我们假设供应链每个阶层只有一个企业,则具体供应链体系结构如图 3.1 所示。



在大数据背景下架构的供应链体系中，物流、资金流和信息流都能够通过大数据分析平台进行快速收集、处理以及传达，每个成员所获得信息不再局限于与之相连的上下游企业，而是来自经过大数据分析平台融合后整个供应链的共享资源。使得供应链实现一体化的运作模式，提高了整个供应链的运营效益。

3.2 Agent 系统与 Multi-Agent 系统

为了进一步在大数据背景下的供应链体系中研究需求预测等问题，引进 Agent 理论，将供应链中各个节点企业概括成独立的 Agent 成员。利用多 Agent 系统(Multi-agent System, MAS)模拟大数据背景下的供应链体系结构。

Agent 是一种可以把复杂的实体抽象为单独的个体行为，然后通过互相的协调控制完成相应任务的计算系统。由于 Agent 系统具有显著的自主性、交互性、反应性和主动性的特征，使得系统具有一定程度的智能化和自制管理特性。Multi-Agent 系统(MAS)是多个 Agent 组成的集合，是一种分布式自主系统，其多个 Agent 成员之间相互协调，相互服务，共同完成一个目标任务。MAS 中每一个主体具有有限信息资源和问题求解能力，并且在系统中不存在全局控制，其中的数据与知识都是分散的，计算也是异步执行的。各 Agent 成员之间的活动服从自治独立的原则，其自身的目标和行为不受其它 Agent 成员的限制，它们通过竞争和磋商等手段协商和解决相互之间的矛盾和冲突。MAS 主要研究目的是通过多个 Agent 所组成的交互式团体来求解超出 Agent 个体能力的大规

模复杂问题。目前，MAS 在计算机科学与应用领域，以及人工智能交互模型的构建与分析都有突破性的应用。引入 Agent 思想研究供应链，可以较好的适应大数据背景下供应链灵活多变的特点，使得供应链中的各项运营活动实现高效的运作。根据系统中 Agent 的通信和协调的方式，可以将 MAS 分为以下三种常见类型，如图 3-2 所示，它们分别是：集中型结构、分散型结构和联邦型结构；其中联邦型结构应用最为广泛，它不仅融合了其他两种结构类型的优势，并克服了它们两则之间的缺陷和不足，对于分布式的多级 Agent 系统以及复杂问题的求解具有更强的适应和处理能力，所以本文选择联邦型 MAS 抽象模拟大数据背景下的供应链需求模型，具体的结构模型如图 3.2—3.4 所示。



图 3.2 集中型结构




图 3.3 分散型结构




图 3.4 联邦型结构

3.3 基于 Multi-Agent 系统的供应链

Agent 系统具有自主性、主动性等特性，尤其具有优异的交流性，因此，基于多 Agent 系统的供应链模型能够较好解决分布式环境下供应链的信息共享问题。采用 Multi-Agent 系统对供应链进行建模，不仅使得整个供应链具有一定程度的智能化特性，而且让该系统中供应链上每个节点成员都具有独立运行和信息搜集与处理的能力，并把所有数据信息整合在一起进行资源交流和共享，同时建立一个控制管理预测算法机制的 Agent 来模拟整个供应链的需求预测。基于 Multi-Agent 系统的供应链的结构模型如图 3.5 所示。

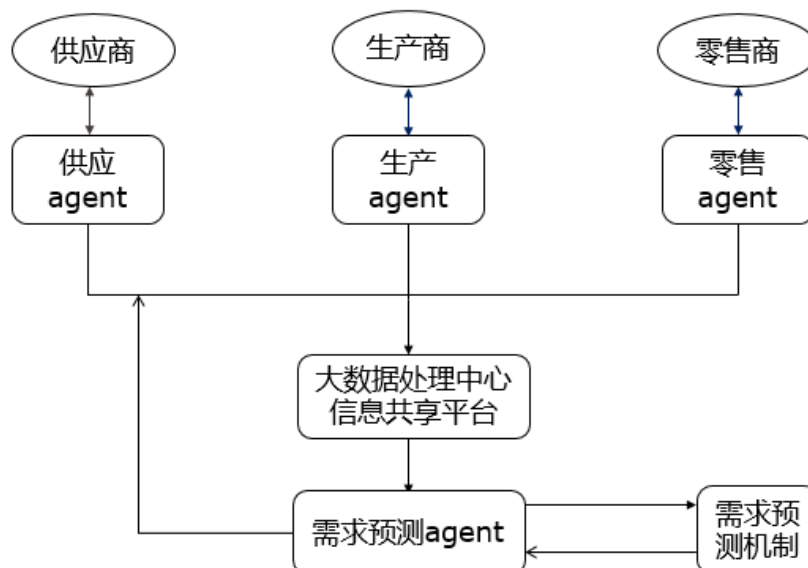


图 3.5 大数据背景下基于 Multi-Agent 系统的供应链模型

相比于传统供应链，大数据背景下基于 Multi-Agent 系统的供应链模型将供应链上

每个企业用独立的 Agent 来模拟，把节点成员的各项功能抽象成联邦型 Agent。因此，按照 Agent 的功能可以将该供应链系统分为以下两类，即分级 Agent 和需求 Agent。其中分级 Agent 是联系供应链其他成员的纽带同时对自身进行信息管理；这类 Agent 的主要作用是收集来自对应节点的相关历史数据，如企业的运营利润、生产成本、库存水平、运输成本、用户需求、政府政策、价格变化等，然后将这些整理后的数据汇总一起传递到数据共享平台中。对于供应链系统中的需求 Agent 则是通过数据共享平台与分析 Agent 保持紧密的信息交流，具备对外界各种多变复杂的信息做出快速反应的能力。其主要工作是从数据共享平台获取并处理历史数据，根据需求预测机制，利用相关预测算法对供应链下个阶段的市场需求做出评估，最后将预测信息重新反馈到各级节点企业以便于供应链管理者协调各个企业做出最优的决策。

由以上分析可知，在大数据的背景下供应链中的企业实现了相互之间的信息共享，这也导致了供应链的结构发生变化，使得其具备了新的特点。与传统的供应链相比，大数据背景下的供应链更加智能灵活，为了进一步研究供应链结构的变化以及自身所具备的新特点给预测机制带来的影响，本章采取 agent 系统模拟大数据背景下的供应链模型，并在此基础上根据供应链新的特点构建新的预测机制。

3.4 本章小结

本章在 Multi-Agent 系统的基础上建立了大数据背景下的供应链模型。首先通过分析大数据环境下供应链的特点，架构基于大数据的供应链体系结构；然后通过引入 Agent 原理和 Multi-Agent 系统来解决供应链成员之间信息共享问题以及提高供应链对分布式环境的适应能力；最后在以上的研究基础上提出大数据背景下基于 Multi-Agent 系统的供应链模型。

第4章 大数据背景下基于遗传算法的支持向量机需求预测与牛鞭效应的研究

由第三章分析可知在大数据的背景下供应链的结构和特点发生了变化,由于大数据背景下供应链时刻面临复杂多变的市场环境以及大数据的数据增长和处理速度快的特征,使得供应链上企业必须对市场需求作出迅速反应,为供应链的需求预测带来了以下几个问题:节点成员在面对市场需求不确定、变化大等问题,在一般的预测机制下快速响应客户需求时可能导致需求预测误差增大。本章针对以上问题,提出了基于遗传算法的支持向量机需求预测,利用遗传算法对支持向量机中的相关参数进行寻优,减少了参数的计算量和选择时间,并且能够对参数进行高效率、高精度地快速搜索,使得企业在快速响应市场需求的基础上有效的降低了需求预测误差和缓解了供应链的牛鞭效应。

4.1 支持向量机预测模型

支持向量机(Support Vector Machine, SVM)是 Corinna Cortes 和 Vapnik 等人在 1995 年首先提出的,它是在统计学习理论的 VC 维理论和结构风险最小原理的基础上构造数学模型,通过有限的样本信息在模型的复杂性(即对特定训练样本的学习精度)和泛化能力(即无错误地识别任意样本的能力)之间寻求最佳平衡状态,以求获得最好的泛化能力;它在解决非线性问题及高维模式识别中表现出许多特有的优势,并能够推广应用到函数拟合等其他机器学习问题中。

目前,支持向量机最主要的应用是对数据进行分类和回归。而支持向量机的回归原理是在分类思想的基础上演变而来,它的基本模型是定义在特征空间上的间隔最大的线性分类器,简单的模型是复杂模型的基础,也是复杂模型的特殊情况,当训练数据具有非线性特征时,通过使用核技巧及软间隔最大化,建立非线性支持向量机的回归模型。

4.1.1 线性可分支持向量机

线性支持向量机的目标是在特征空间中找到一个分离超平面,从而能够将训练数据集分到不同类别。一般来说,当训练数据集线性可分时,存在无穷个分离超平面可将两类数据正确分开,而线性可分支持向量机则是利用间隔最大化确定唯一的最优分类超平面。

如图 4.1 所示,在超平面 $\omega \cdot x + b = 0$ 上分别用黑色点和白色点代表两类线性可分的训练样本,其中 H 表示一条将训练样本分开的分类线, H_1 和 H_2 平行于 H 且分别经过离 H 最近的两类实例点。 H_1 与 H_2 之间形成了一条长带,长带的宽度,即 H_1 与 H_2 之间的距离称为间隔,使得间隔达到最大的 H 就是最优分类线。将其应用到高维空间,最

优分类线即为最优分类面。




图 4.1 线性可分最优分类面

通过以上描述可知，线性支持向量机学习的基本想法就是求解能够正确划分训练数据集并且间隔最大的分离超平面，因此如何计算最优分类面是支持向量机学习的关键。根据间隔最大化理论可以将求解最优分类面问题转化为如下所示的一个凸二次规划问题的求解。

假设给定一个特征空间上训练数据集

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\} \quad (4.1)$$

其中 $x_i \in \mathcal{X} = R^n, y_i \in Y = \{+1, -1\}, i = 1, 2, \dots, N$, x_i 为第 i 个实例(特征向量), y_i 为 x_i 的类标记。构造如下的约束最优化问题

$$\begin{aligned} \max_{\omega, b} \frac{2}{\|\omega\|} &\Leftrightarrow \min_{\omega, b} \frac{1}{2} \|\omega\|^2 \\ \text{s. t.} & \\ y_i(\omega \cdot x_i + b) - 1 &\geq 0, i = 1, 2, \dots, N \end{aligned} \quad (4.2)$$

通过求解上述二次规划问题的最优解 ω^* 和 b^* ，由此可得最大间隔分离超平面 $\omega^* \cdot x + b^* = 0$ 及分类决策函数 $f(x) = \text{sign}(\omega^* \cdot x + b)$ ，即得到线性可分支持向量机模型。

4.1.2 支持向量机需求预测模型的构建

支持向量机回归原理是对支持向量机分类理论的延伸及推广，当样本数据集线性可分时，则上一节中的最优分类超平面 $f(x) = \omega^* \cdot x + b^*$ 可直接用于回归函数的拟合。然而在实际的需求预测中，市场需求往往呈现一种非线性变化的趋势。所以，在面临数据集具有非线性特征的时候，我们通常需要通过一个非线性变换 $\Phi(\cdot)$ ，把样本数据集从样本空间映射到一个高维的特征空间中，使得在原来的样本空间中的非线性问题转换为在特征空间中的线性问题，通过求解变换后的线性问题的方法求解原来的非线性问题。简单的说，非线性支持向量机的学习过程就是升维和线性化，使其可以转化为简单的线性函数回归。其模型的基本结构如图 4.2 所示：




图 4.2 支持向量机模型基本结构图

假设给定一个样本数据集 $S = \{(x_i, y_i) \mid i=1, \dots, n, x_i \in R^n, y_i \in R\}$ ，其中 x_i 为输入变量， y_i 为对应的预测值，假设输入变量与预测值遵循未知的函数关系 $y = f(x)$ 。运用非线性支持向量机学习方法，构建需求预测模型。首先，设回归函数为：

$$g(x) = \omega \cdot \phi(x) + b \quad (4.3)$$

其中 $\omega \in R^n$ 为权值矢量， $b \in R$ 为偏置。由结构风险最小化原理可知，利用上式 (4.3) 对训练数据集进行函数拟合，并使函数 f 与 g 之间的距离最小，即回归函数 g 应使得 $J = \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^n L(g(x_i), y_i)$ 最小，其中： J 表示经验风险， $\|\omega\|^2$ 为置信风险，

$CL(g(x_i), y_i)$ 为损失函数。故 ω 与 b 可通过如下最优化问题求解获得。

$$\begin{aligned} \min & \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \\ s.t. & \\ & y_i - \omega \cdot \phi(x_i) - b \leq \xi_i + \varepsilon \\ & \omega \cdot \phi(x_i) + b - y_i \leq \xi_i^* + \varepsilon \\ & \xi_i, \xi_i^* \geq 0, \quad i = 1, 2, 3 \cdots n \end{aligned} \quad (4.4)$$

在上式 (4.4) 中, C 是惩罚因子, ξ_i, ξ_i^* 为松弛因子, ε 为不敏感因子。当输入变量和预测值表现出非线性关系时, 引入核函数 $K(x_i, x_j)$ 将非线性优化问题转化为线性问题。为了进一步求解转化后的线性最优化问题, 应用拉格朗日对偶性, 通过求解对偶问题得到原始问题的最优解。

首先构建拉格朗日函数 (4.5), 为式 (4.4) 中每一个约束条件引进拉格朗日乘子 $\alpha_i \geq 0, i = 1, 2, \cdots, n$, 定义如下拉格朗日函数:

$$\begin{aligned} L(\omega, b, \alpha_i, \alpha_i^*) = & \\ & \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) - \sum_{i=1}^n \alpha_i (\xi_i + \varepsilon - y_i + \langle \omega \cdot \phi(x_i) \rangle + b) \\ & - \sum_{i=1}^n \alpha_i^* (\xi_i^* + \varepsilon + y_i - \langle \omega \cdot \phi(x_i) \rangle - b) - \sum_{i=1}^n (\eta_i \xi_i + \eta_i^* \xi_i^*) \end{aligned} \quad (4.5)$$

根据拉格朗日对偶性, 原始问题的对偶问题是极大极小问题:

$$\max_{\alpha, \alpha^*} \min_{\omega, b, \xi_i, \xi_i^*} L(\omega, b, \alpha, \alpha^*) \quad (4.6)$$

所以, 为了得到对偶问题的解, 需要先求朗格朗日函数对 $\omega, b, \xi_i, \xi_i^*$ 的极小, 再求对 α_i, α_i^* 的极大。

由拉格朗日函数取极小值时的必要条件可知式 (4.5) 对 $\omega, b, \xi_i, \xi_i^*$ 的偏导数均为零。即有以下约束条件:

$$\nabla_{\omega} = 0 \Leftrightarrow \omega = \sum_{i=1}^n (\alpha_i^* - \alpha_i) \phi(x_i) \quad (4.7)$$

$$\nabla_b = \sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0 \quad (4.8)$$

$$\nabla_{\xi_i} = C - \alpha_i - \eta_i = 0 \quad (4.9)$$

$$\nabla_{\xi_i^*} = C - \alpha_i^* - \eta_i^* = 0 \quad (4.10)$$

将上述式子带入拉格朗日函数 (4.5) 后可得对偶问题的目标函数，然后求解该目标函数对 α_i , α_i^* 最大化问题，即可利用拉格朗日函数将原始最优化问题 (4.4) 转化为其对偶问题。具体数学模型如下所示：

$$\begin{aligned} & \max \left[-\frac{1}{2} \sum_{i,j=1}^n (\alpha_i - \alpha_i^*) (\alpha_j - \alpha_j^*) K(x_i, x_j) \right. \\ & \quad \left. - \varepsilon \sum_{i=1}^n (\alpha_i - \alpha_i^*) + \sum_{i=1}^n y_i (\alpha_i - \alpha_i^*) \right] \\ & s.t. \\ & \sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0 \\ & 0 \leq \alpha_i, \alpha_i^* \leq C, i = 1, 2, \dots, n \end{aligned} \quad (4.11)$$

式中 α_i, α_i^* 为拉格朗日乘子。根据 KKT 条件可知当 α_i, α_i^* 是对偶问题 (4.11) 的一个解时， ω , b 可按下式求得：

$$\omega = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \phi(x_i) \quad (4.12)$$

$$b = \frac{1}{N_{Nsv}} \left\{ \sum_{0 \leq \alpha_i \leq C} \left[y_i - \sum_{x_j \in SV} (\alpha_j - \alpha_j^*) K(x_j, x_i) - \varepsilon \right] \right. \\ \left. + \sum_{0 \leq \alpha_i^* \leq C} \left[y_i - \sum_{x_j \in SV} (\alpha_j - \alpha_j^*) K(x_j, x_i) + \varepsilon \right] \right\} \quad (4.13)$$

其中式 (4.13) 中的 N_{Nsv} 表示标准支持向量的个数，当 $\alpha_i \neq \alpha_i^*$ 时对应的训练样本点即为标准支持向量。通过如下 (4.14) 与 (4.15) 的形式对给定的样本数据集进行训练样本对和预测样本输入的构造。

$$X_{train} = \begin{bmatrix} X_1 & X_2 & \cdots & X_m \\ X_2 & X_3 & \cdots & X_{m+1} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n-m} & X_{n-m+1} & \cdots & X_{n-1} \end{bmatrix} \quad Y_{train} = \begin{bmatrix} X_{m+1} \\ X_{m+2} \\ \vdots \\ X_n \end{bmatrix} \quad (4.14)$$

$$X_{test} = \begin{bmatrix} X_{n-m+1} & X_{n-m+2} & \cdots & X_n \\ X_{n-m+2} & X_{n-m+3} & \cdots & X_{n+1} \\ \vdots & \vdots & \ddots & \vdots \\ X_{N-m+1} & X_{N-m+2} & \cdots & X_N \end{bmatrix} \quad (4.15)$$

利用训练样本对求解上述对偶优化问题 (4.11), 可得拉格朗日乘子 α_i, α_i^* 的值, 将其带入式 (4.12) 和式 (4.13) 可得 ω 和 b , 然后根据式 (4.3) 建立需求预测回归函数。即

$$f(x) = \sum_{i=1}^k (\alpha_i - \alpha_i^*) K(x_i, x) + b \quad (4.16)$$

最后将预测样本输入上述回归函数 (4.16) 计算预测样本输出, 得到下一阶段的需求预测值。

4.1.3 支持向量机模型的核函数及其参数选择

核函数的使用可以将线性支持向量机学习方法推广应用到非线性问题中去, 由上一节可知非线性支持向量机的核心是通过一个非线性映射将变量映射到高维的特征空间中从而转化为线性问题。如果直接在高维空间进行分类或回归, 则存在确定非线性映射函数的形式和参数、特征空间维数等问题。由于在高维的特征空间中线性支持向量机的求解只涉及输入实例与实例之间的内积, 引入核函数 $K(x_i, x_j)$ 来替代样本数据间的点积运算 $\phi(x_i) \cdot \phi(x_j)$, 可以大大的简化高维空间中复杂的内积运算, 从而巧妙的解决了在高维特征空间中计算的“维数灾难”等问题。在实际应用中, 往往依赖领域知识直接选择核函数, 目前, 最常用的核函数主要有多项式核函数和高斯核函数, 其表达形式分别如式 (4.17)、(4.18) 所示。

多项式核函数:

$$K(x_i, x_j) = (x_i \cdot x_j + 1)^p \quad (4.17)$$

高斯核函数:

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right) \quad (4.18)$$

上式中 p 表示多项式核函数的阶数; σ 是核宽度系数, 表示高斯函数的均方差, 其中高斯核函数是一个普适的核函数, 调整核参数 σ 后它可以适用于任意分布的样本, 因此本文选择高斯核函数构造支持向量机回归模型。

在利用支持向量机构造需求预测回归函数时, 模型参数的选择对于回归函数的拟合

精度至关重要,影响模型预测性能的主要参数有惩罚因子 C 、核参数 σ 以及不敏感因子 ε , 因此, 如何选择有效的模型参数是提高支持向量机预测精度和预测时间的关键

(1) 惩罚因子 C

惩罚因子 C 是模型复杂度和推广能力的折中, 用来权衡模型复杂度和样本允许出错的大小, 它决定了对损失大于 ε 的样本的惩罚程度, 当 C 趋于无穷大时, 模型优化目标退化为经验风险最小化, 也就是一个样本也不允许出错。所以说, C 越大, 允许出错的样本越小, 模型复杂度越高, 越容易过拟合。当 C 过小, 使经验风险所占比重太少, 模型结构复杂度下降, 但训练误差可能超出接受范围。

(2) 不敏感因子 ε

不敏感因子 ε 是支持向量机回归模型的重要特征, 它决定了支持向量的数目。保证了解的稀疏性, 是模型推广性能的象征, 但是太平滑的估计又会降低模型的精度。

(3) 核参数 σ

核参数 σ 反映了训练数据的范围或分布情况, 确定了局部领域宽度的大小, σ 越小方差越大。当 σ 过大时, 模型对训练数据的拟合能力较差, 发生“欠学习”的现象, 反之, 若 σ 过于小时, 无法确保模型对预测数据泛化能力, 出现“过学习”现象。因此, σ 的选定对模型的预测效果影响较大。

目前没有一个理论的方法来设计支持向量机的参数, 现有的软件都是基于建模者的经验在建模之前设定的。常用的设定模型参数的方法主要有: 试凑法、交叉验证法、经验选择法和网格优化选择法。

4.2 基于遗传算法的支持向量机预测模型的优化

4.2.1 遗传优化算法

由上一节可知一个支持向量机回归的性能在很大程度上取决于模型参数的设置, 选择一组最优的参数组合对于提高模型的预测效果具有非常重要的意义。然而在传统设定参数的方法中, 参数的确定往往依赖建模者的经验从而使得模型的训练时间过长以及拟合程度不高。为了解决上述问题, 本文采用遗传优化算法对支持向量机模型中的各个参数进行寻优处理。

遗传算法 (genetic algorithm, GA) 是模拟达尔文生物进化论的自然选择和遗传学机理的生物进化过程的计算模型, 是一种通过模拟自然进化过程搜索最优解的方法, 从代表问题可能潜在的解集的一个种群开始, 然后根据问题域中个体的适应度大小选择个体, 并借助遗传算子进行组合交叉和变异, 产生出代表新的解集的种群, 通过不断地循环, 直到满足约束条件选择出问题的近似最优解。该算法具有全局择优、自适应和并行化等特性, 避免了陷入局部最优的风险, 所以, 利用遗传算法对支持向量机算法的模型参数进行优化可以有效的保障其模型的推广和泛性能。本文设计如下的遗传算法对模型

参数进行用全局寻优。

(1) 设计遗传算法的适应度函数。

适应度函数是计算个体在群体中被使用的概率，为了确定个体的适应值，首先利用训练数据集建立支持向量机预测模型，然后通过该模型对预测样本进行预测，根据本文研究目的，利用预测值与实际值的均方误差来衡量个体的适应度。适应度函数的具体表达式如下所示：

$$f_i = \frac{1}{MSE} \quad (4.19)$$

式 (4.19) 中， $MSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - y_i^*)^2}$ 表示支持向量机预测模型的均方误差，由

此可见均方误差越小，表示需求误差越小，该个体的适应值也就越大。

(2) 选择操作

选择操作是建立在群体中个体的适应度评估基础上的。本文采用轮盘赌选择法，在该方法中，各个个体的选择概率和其适应度值成正比。设群体大小为 n ，其中个体 i 的适应度为 f_i ，则 i 被选择的概率为

$$p_i = \frac{f_i}{\sum_{i=1}^n f_i} \quad (4.20)$$

由此可知，选择概率反映了个体 i 的适应度在整个种群中所占的比例。个体适应度越大，其被选择的概率就越高，反之亦然。

(3) 交叉操作

交叉操作是遗传算法中的核心步骤，通过交叉，可以把两个父代个体的部分结构加以替换重组而生成新的个体，从而提高算法的寻优搜索的能力，这里，我们采用线性交叉方式，具体形式如下所示：

$$x_1' = \lambda x_1 + (1 - \lambda)x_2 \quad (4.21)$$

$$x_2' = (1 - \lambda)x_1 + \lambda x_2 \quad (4.22)$$

其中， λ 表示在 0 到 1 之间随机生成的数。

(4) 变异操作

通过变异操作可以提高算法的局部搜索能力，加快算法向最优解的收敛速度。在需要进行变异操作的个体 i 中随机选择一个变异位利用变异算子进行变动。构造如下变异算子：

$$X_i' = X_i + \Delta \quad (4.23)$$

式(4.23)中 Δ 是一个很小的随机实数。

4.2.2 遗传算法优化支持向量机参数

本文采用高斯核函数求解支持向量机来构造需求预测回归函数。由上文可知,惩罚因子 C 、核参数 σ 以及不敏感因子 ε 是影响支持向量机回归模型的重要参数。遗传算法优化模型参数的过程就是根据所设计的适应度函数对个体进行评估和选择,然后借助于一系列的遗传操作搜索出最优参数组合。通过利用上述所设计的遗传算法对支持向量机模型的参数进行优化求解需求预测回归函数的具体步骤如下所示:

- (1) 首先确定支持向量机模型中惩罚因子 C 、核参数 σ 和不敏感因子 ε 的区间范围,设置遗传算法中种群规模的大小、最大进化代数、交叉概率以及变异概率等参数。
- (2) 确定遗传算法中个体的编码长度,通过编码随机生成初始群体 $P(t)$ 。
- (3) 对初始群体中的每个个体,带入到支持向量机模型中,利用训练样本建立支持向量机预测模型得到预测样本下的预测值,然后计算在对应个体下支持向量机预测模型的均方误差,最终得到初始种群中每个个体的适应值。
- (4) 通过遗传算子进行选择交叉和变异,产生出新一代的种群。
- (5) 当新种群中的个体适应度达到给定的阈值,或者个体的适应度和群体适应度不再上升时,或者迭代次数达到预设的代数时,停止算法;否则,转至步骤(3),直到满足上述条件。此时,新生成的种群中适应值最高的便是种群的最优个体,即为支持向量机预测模型的最有参数组合。
- (6) 将最优参数组合带入支持向量机回归模型中,求解需求预测回归函数,得到需求预测值。

基于遗传算法的支持向量回归机的算法流程如图4.3所示。

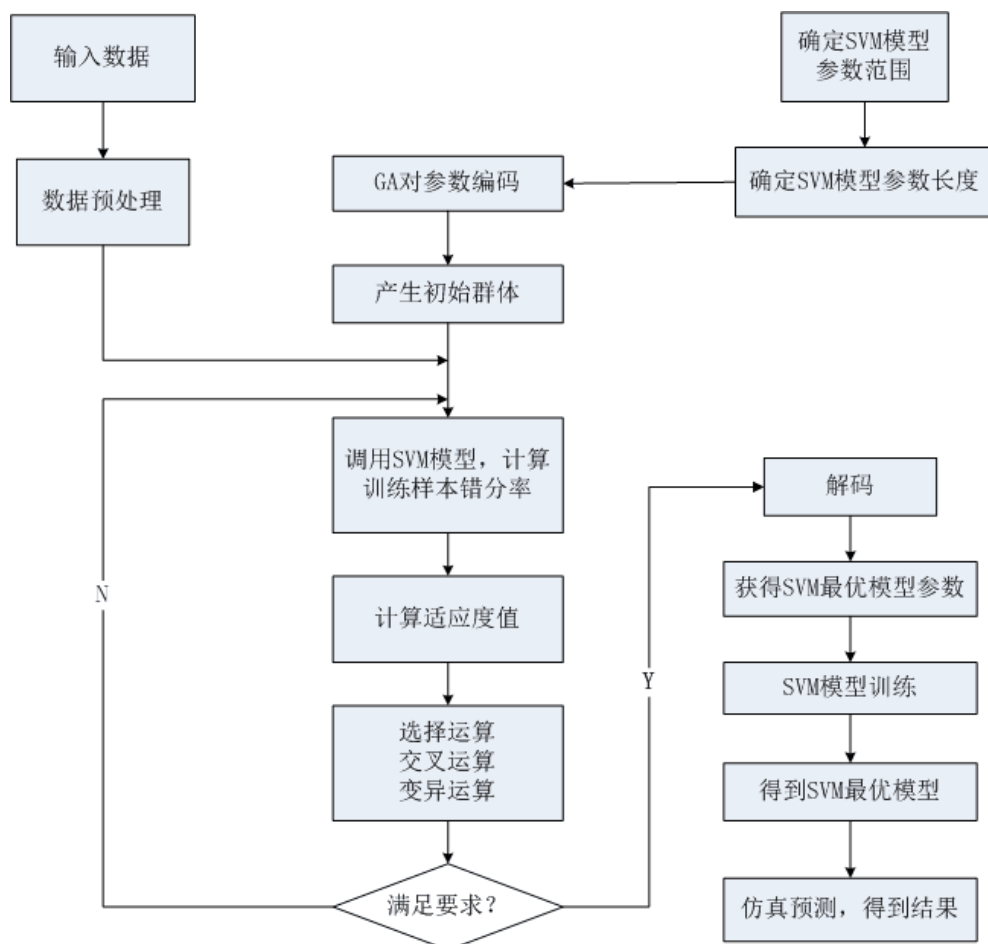


图 4.3 基于遗传算法的支持向量机参数优化流程

4.3 实例分析

4.3.1 需求预测分析

为了说明基于遗传算法的支持向量机预测模型的性能优于传统的向量机预测模型，本文分别设计了通过利用传统的预测模型和优化后的模型对某时尚电子产品的销量进行预测分析的实验。该电子产品在各月的销量如下表 4.1 所示：

表 4.1 某电子产品每月销售数据

	销售月份								
	1	2	3	4	5	6	7	8	9
实际销量	37	55	74	70	83	96	90	95	84
销售月份	10	11	12	13	14	15	16	17	
实际销量	87	91	62	49	41	40	35	26	

首先将表 4.1 中的数据按照比例分为训练样本对和测试样本，其中前十五个月的销

量作为训练样本，后三个月的销量作为测试样本，然后根据传统的参数设定——经验选取法确定参数 $C=50$ ， $\sigma=20$ ，构造支持向量机预测模型，并通过模型拟合出预测结果；其次利用遗传算法搜索支持向量机模型中的惩罚因子 C 、核参数 σ 以及不敏感因子 ε 的最优参数组合，其中各个参数的寻优区间分别为： $C \in [1,10000]$ ， $\varepsilon \in [0.0001,0.1]$ ， $\sigma \in [0.01,500]$ ，同时将遗传算法中涉及的变量设置如下：种群规模为 30，最大进化代数为 100，交叉概率为 0.95，变异概率为 0.05。通过 MATLAB 编程实现遗传算法的寻优过程，得到最优参数组合 $C=48.5141$ ， $\sigma=10.3045$ ， $\varepsilon=0.0100$ ，最后将最优参数代入支持向量机模型中，利用训练样本对构造需求预测回归函数，并用该预测模型对测试样本数据进行拟合得到预测结果。将传统的支持向量机预测结果和基于遗传算法的支持向量机模型的预测结果整理如下表 4.2 所示。

表 4.2 支持向量机预测模型优化前后的拟合预测值

	销售月份								
	1	2	3	4	5	6	7	8	9
实际销量	37	55	74	70	83	96	90	95	84
传统 SVM 预测销量	30	37	46	55	65	75	83	89	92
改进 SVM 预测销量	43	56	71	86	99	107	110	106	98
销售月份	10	11	12	13	14	15	16	17	
实际销量	87	91	62	49	41	40	35	26	
传统 SVM 预测销量	91	87	81	72	63	53	44	85	
改进 SVM 预测销量	87	75	63	53	44	38	33	29	

由上表的数据对比可知，相比于传统的支持向量机预测模型，采用基于遗传算法优化参数后的模型对该电子产品的销量进行预测的结果更加接近实际的市场销售情况，对下一阶段未来的需求具有更好的预测效果。为了更加形象的对比两模型之间预测性能的优劣，图 4.4 和图 4.5 分别描述传统的支持向量机预测模型和优化模型对历史数据的拟合程度以及在两种模型下需求预测的效果。




图 4.4 传统 SVM 预测模型数据拟合图




图 4.5 改进 SVM 预测模型数据拟合图

根据图 4.4 与图 4.5 的对比，我们可以发现传统的支持向量机预测模型不仅无法对

训练样本数据进行准确的拟合，而且在测试样本的拟合预测上也没有达到理想效果，而基于遗传算法优化后的支持向量机预测模型对该产品的销量具有较好的拟合度，波动幅度相对于较小，并且能够更准确的对下一阶段需求进行预测。

为了进一步说明基于遗传算法的支持向量机模型在预测的其他方面性能，下表 4.3 分别对比了两种预测模型在进行需求拟合时的各个参数的寻优精度、模型的训练次数以及需求拟合的均方误差值。

表 4.3 支持向量机优化前后的寻优精度、所需训练次数与预测误差

模型	寻优间隔			训练次数	均方误差
	惩罚因子	核参数	不敏感因子		
改进 SVM	10	0.12	0.0002	1200	7.73E-05
传统 SVM	500	25.00	0.0050	8000	3.89E-04

从中不难发现，基于遗传算法改进后的支持向量机模型不仅在预测精度上有了明显的提高，同时减少了模型的训练次数大大加快了预测速度，实验结果表明利用遗传算法优化支持向量机是克服传统预测模型缺点的有效方法，从而更加适应大数据背景下供应链需求预测的特征。

4.3.2 牛鞭效应分析

需求预测是引起供应链产生牛鞭效应的一个关键原因，因此，本文从供应链需求预测的角度去探讨通过优化预测模型提高预测精度是否对牛鞭效应具有缓解作用，为了说明在该优化模型下牛鞭效应的强弱，同时为了方便计算和突出需求预测对牛鞭效应影响的程度，本文在不考虑供应链库存策略以及影响牛鞭效应其他因素的情况下通过式(2.1)对牛鞭效应进行量化。则供应链中每个节点的订单量可直接看作需求预测值，故通过以上假设和其他条件可分别计算出在传统的支持向量机预测模型和基于遗传算法优化模型下预测值所产生的牛鞭效应，具体数据如下表 4.4 所示，两预测模型下牛鞭效应的波动对比如图 4.6 所示。

表 4.4 支持向量机优化前后牛鞭效应的对比

月份	实际销量	预测销量		牛鞭效应	
		传统 SVM	改进 SVM	传统 SVM	改进 SVM
1	37	30	43	0.189189	0.162162
2	55	37	56	0.327273	0.018182
3	74	46	71	0.378378	0.040541
4	70	55	86	0.214286	0.228571
5	83	65	99	0.216867	0.192771
6	96	75	107	0.218750	0.114583
7	90	83	110	0.077778	0.222222
8	95	89	106	0.063158	0.115789
9	84	92	98	0.095238	0.166667
10	87	91	87	0.045977	0
11	91	87	75	0.043956	0.175824
12	62	81	63	0.306452	0.016129
13	49	72	53	0.469388	0.081633
14	41	63	44	0.536585	0.073171
15	40	53	38	0.325	0.05
16	35	44	33	0.257143	0.057143
17	26	35	29	0.346154	0.115385
牛鞭效应平均值				0.241857	0.107692




图 4.6 不同预测模型下牛鞭效应的波动比较

由上表 4.4 可以看出，传统的支持向量机模型预测时产生的牛鞭效应远远大于使用遗传算法优化后的支持向量机模型进行需求预测时的牛鞭效应。如图 4.6 所示，在优化

的支持向量机预测模型下，不仅供应链牛鞭效应有明显的降低，并且变化更加趋于平缓，相对处于比较稳定的状态。实验结果表明，当需求预测误差越小时，供应链中牛鞭效应越弱、波动越小，因此提高需求预测精度对缓解牛鞭效应具有重要意义。

4.4 本章小结

本章根据大数据背景下供应链的结构和市场需求的特征，提出了基于遗传算的支持向量机预测模型，首先介绍了一般的传统支持向量机模型，讨论模型中参数对拟合预测的影响。然后在此基础上提出利用遗传算法对原有模型的参数进行优化改进，构造基于遗传算法的支持向量机预测模型。该模型充分考虑在大数据背景下企业需快速反应市场需求的特点，克服了传统的预测模型在面对数据不确定、波动大的情况下无法迅速准确的响应市场需求的缺陷，降低了需求预测的误差。最后通过对某电子产品的销售进行拟合预测验证了新模型的预测性能。

第5章 大数据背景下基于多变量支持向量机的需求预测与牛鞭效应的研究

本文第四章提出了基于遗传算法的支持向量机预测模型，能够在保证需求误差时快速的对需求进行预测，然而在该模型中只考虑单变量的需求预测。在供应链中，市场需求往往受到多个因素的影响，并且在大数据环境下供应链中企业更加容易收集到影响需求预测的各因素的相关数据。因此，单一变量的预测方法已经无法达到预测期望，为了提高供应链需求预测的精确度，削弱牛鞭效应，提出一种基于多因素的支持向量机需求预测的方法；通过利用信息熵选取主要影响因素，建立多变量 SVM 预测模型。该模型充分考虑影响市场需求的其他相关因素，最大程度挖掘了数据中的有效信息，提高了需求预测的准确性，从而缓解了供应链的牛鞭效应。

5.1 多变量支持向量机需求预测模型

由于市场需求不仅受到供应链内部成员的作用，其他外部因素对其变化也具有不可忽视的影响，且各个因素相互牵制，这就导致了供应链的需求变化具有非线性不确定的特征。所以独立的采用以往的历史需求数据进行下一阶段的需求拟合是十分不合理的，同时也很难适应复杂多变的市场环境。大数据背景下的供应链使得供应链各企业实现资源共享成为可能，各成员可以更加容易准确的获取影响市场需求的相关因素的数据，这为建立多变量需求预测模型奠定了实际基础。为了适应大数据环境下供应链需求预测的特点，本章在上一章的基础上提出多变量支持向量机预测模型。然而当支持向量机维数增大时，预测效果会受到负面影响而产生波动，导致模型的泛化能力减弱。为了解决模型中存在的这一问题，论文在多变量的支持向量机预测基础上引入 BP 神经网络来减少预测误差，提高模型对数据的拟合精度。通过结合两种算法模型的优点，对大数据环境下供应链进行精确的需求预测。具体操作步骤如图 5.1 所示：

首先，建立影响市场需求指标体系，对多个影响因素进行预处理，引入粗糙集理论通过信息熵来衡量各个影响因素对市场需求的重要度，剔除冗余因子，选取主要因素，从而实现对多因素需求预测指标体系的简化。

然后，区别于单变量的支持向量机，寻找影响因素与市场需求的函数关系，利用与需求相关的影响因素预测下一阶段的市场需求。构造训练样本对和测试样本，将训练样本对带入模型中建立需求预测回归函数，对测试样本进行拟合预测，根据实际值，得到每一阶段的预测误差值。

最后，建立一个多输入单输出的 BP 神经网络，对每一阶段的预测误差进行学习训

练，获得需求误差规律，利用该规律对使用多变量支持向量机预测模型得到的预测值进行调整，弥补了该模型在高维的情况下泛化能力不足的缺陷，降低了需求预测的误差，为大数据背景下供应链需求预测提供有效的预测方法，进而大大的缓解了供应链中的牛鞭效应。

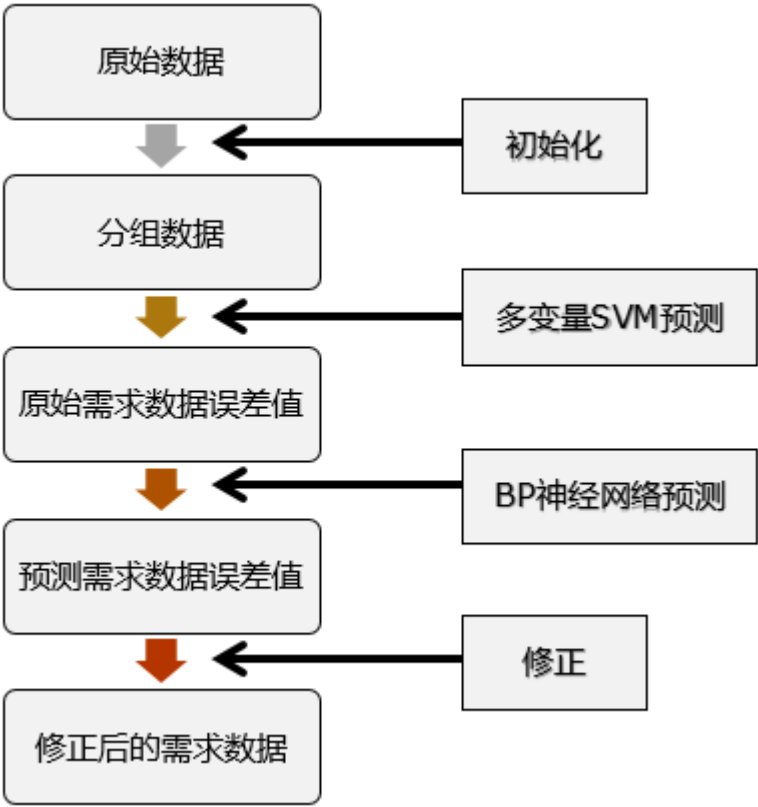


图 5.1 多变量支持向量机需求预测流程

5.1.1 影响因素选取

需求预测与供应链中众多因素都存在一定的联系，为了选取关联关系密切的变量，剔除冗余的影响因子，利用信息熵理论与方法确定各个影响因素的重要程度。首先将影响需求的变量 x_1, x_2, \dots, x_n 作为条件属性，即得到条件属性集 $X = \{x_1, x_2, \dots, x_n\}$ ，将所要预测的需求作为决策属性，得到决策属性集 $D = \{y\}$ ，则各个相关变量与相应需求的历史数据构成一个研究对象 $u_i = \{x_{i,1}, x_{i,2}, \dots, x_{i,n}; y_i\}$ ，论域 $U = \{u_i \mid i=1, 2, \dots, m\}$ 。然后利用熵值法定义每个变量的重要度，预设一个阈值以此为基准，通过比较各变量重要度与阈值大小达到约简变量个数的目的。

定义 $\tilde{X} \subseteq X, U / \tilde{X}$ 上的子集组成的概率分布

$$P(Z) = \frac{\text{card}(Z)}{\text{card}(U)}, Z \in U / \tilde{X} \quad (5.1)$$

式 (5.1) 中 $\text{card}(Z)$ 代表集合 Z 的大小, 即集合 Z 中元素的个数。则该条件属性子集的重要度为:

$$H(\tilde{X}) = - \sum_{Z \in U / \tilde{X}} P(Z) \ln(P(Z)) \quad (5.2)$$

即 $H(\tilde{X})$ 表示条件属性的信息熵。根据上式可得关于条件属性子集 \tilde{X} 对于决策属性 D 的条件信息熵为

$$H(D | \tilde{X}) = - \sum_{Z \in U / \tilde{X}} P(Z) \sum_{Y \in D} P(Y | Z) \ln P(Y | Z) \quad (5.3)$$

式 (5.3) 中 $P(Y|Z) = \text{card}(Y \cap Z) / \text{card}(Z)$, $H(D | \tilde{X})$ 合理的度量了条件属性集 \tilde{X} 对于决策属性 D 的影响大小, 若 $H(D | \tilde{X})$ 越大, 则影响越大, 反之越小。考虑到每个变量因素对决策变量的影响大小, 假设

$$X_j = X - \{x_j\}, j = 1, 2, 3, \dots, n \quad (5.4)$$

那么各个影响变量的信息熵可定义为:

$$\lambda(x_j, X, D) = H(D | X_j) - H(D | X), j = 1, 2, 3, \dots, n \quad (5.5)$$

若 $\lambda(x_j, X, D)$ 越小, 则变量 x_j 对决策变量 y 的影响越大, 然后将其和预设阈值进行比较, 剔除冗余变量, 确定简化后的影响因素的集合 $X^* = (x_1, x_2, \dots, x_N)$ 。

5.1.2 多变量支持向量机预测模型

对于单变量 SVM 预测模型, 通常利用前 p 个时刻的值, 对当前或未来时刻的值进行预测, 认为预测值与其前面的 n 个值之间存在某种函数关系, 即

$$y(i + n + 1) = F(y(i), y(i + 1), \dots, y(i + m)) \quad (5.6)$$

然而由于序列历史数据的随机性的干扰, 单变量支持向量机的预测结果会受到数据波动的影响。而多变量支持向量机通过选取主要影响因素, 考虑到了多个变量的相互影响和制约, 摆脱了不确定因素的影响, 从而获得更加精确的需求预测结果。采用多变量支持向量机构建需求预测模型, 挖掘需求量 y 与多个变量 x_1, x_2, \dots, x_n 之间的关系, 即

$$y_i = F(x_1(i), x_2(i), \dots, x_n(i)) \quad (5.7)$$

根据信息熵理论完成主要因素选取后, 以 $X_i = (x_{i1}, x_{i2}, \dots, x_{in})$ ($i=1, 2, \dots, m$)

为输入，对应的需求量 y_i 为输出，组成如下 (5.8)、(5.9) 所示的训练样本对以及预测样本输入：

$$X_{train} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1n} \\ X_{21} & X_{22} & \cdots & X_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ X_{m1} & X_{m2} & \cdots & X_{mn} \end{bmatrix} \quad Y_{train} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} \quad (5.8)$$

$$X_{test} = \begin{bmatrix} X_{m+1,1} & X_{m+1,2} & \cdots & X_{m+1,n} \\ X_{m+2,1} & X_{m+2,2} & \cdots & X_{m+2,n} \\ \vdots & \vdots & \ddots & \vdots \\ X_{M1} & X_{M2} & \cdots & X_{Mn} \end{bmatrix} \quad (5.9)$$

然后基于所给训练样本对，求解拉格朗日乘子，建立需求预测回归函数。即

$$f(x) = \sum_{i=1}^k (\alpha_i - \alpha_i^*) K(x_i, x_j) + b \quad (5.10)$$

最后将预测样本输入回归函数计算预测样本输出，得到下一阶段的需求预测值。

5.1.3 BP 神经网络误差修正

由于支持向量机模型用于多变量的需求预测，大大增加了向量维数，使得模型的泛化能力减弱，针对这个问题，本文采取 BP 神经网络来控制预测误差，提高模型的拟合度。BP 神经网络是一种多层前馈神经网络，由输入层、隐含层和输出层组成。本文采用基本 BP 神经网络算法，该算法主要包括两方面：信号的前向传播和误差的反向传播。首先正向传播输入信息，然后利用输出后的误差来估计输出前一层误差，如此获取所有各层误差估计。这里的误差可以看做某种偏导数，根据这种偏导数来调整各层的连接权值，再用调整后的连接权值重新计算输出误差。直到输出的误差达到符合的要求或者迭代次数溢出的设定值。其网络结构如图 5.2 所示：




图 5.2 BP 神经网络结构

利用以上 BP 神经网络进行误差修正时,首先根据多变量支持向量模型得到预测值,对比原始数据,获得相应的预测误差值。然后将该误差值分为训练样本和测试样本,利用训练样本学习误差规律,将测试样本代入得到经过调整后各个阶段的预测误差值,最后将修正后的误差值与多变量支持向量机模型所得预测值相加即可得调整后的需求预测值。

5.2 实例分析

5.2.1 需求预测分析

为了验证该算法的预测效果,构造含有两个参数的非线性函数进行仿真实验,令 $y = -2x_1^2 - x_2 - x_1x_2 + 100$, $x_1 \in [0,2], x_2 \in [0,5]$ 。函数中自变量 x_1 与 x_2 表示影响需求的因素,而多项式函数则模拟需求值与各个因素之间的映射关系。每个自变量均匀生个 200 个点,根据函数多项式可得到对应的 y 值。在 MATLAB2015 提供的支持向量机工具箱的基础上进行编程。通过仿真验算,分别采用单变量支持向量机和基于 BP 神经网络的多变量支持向量机对 120 组数据进行训练,其余 80 组数据进行预测,仿真数据和仿真结果分别如图 5.3, 5.4 所示。




图 5.3 仿真数据




图 5.4 单变量 SVM 与多变量 SVM 预测对比图

为了衡量算法预测性能, 分别计算该预测值的绝对平均误差、均方根误差、平均相对误差和归一化均方误差, 结果如下表 5.1 所示。

表 5.1 单变量支持向量机与多变量支持向量机预测误差对比

模型	绝对平均 误差	均方根 误差	归一化均方 误差	平均相对 误差
单变量 SVM	11.2369	14.7180	15.950	0.2550
多变量 SVM	0.4321	0.5820	0.0250	0.0090

由表 5.1 可以看出多变量 SVM 对于没有噪声的两输入非线性函数预测精度到达 0.9%，远远低于单变量 SVM 的预测误差。根据图 5.4 所示，可以发现多变量 SVM 预测模型相对于单变量 SVM 具有更好的拟合度，摆脱了历史数据随机性的影响，预测结果十分接近真实值。

为了进一步验证该算法在实际生产运作中也具有良好的预测能力，本文采用某电子产品的需求预测进行试验分析，影响该电子产品的市场需求因素很多，主要有制造成本（I₁）、季节变化（I₂）、销售力度（I₃）、市场特征（I₄）、进店人数（I₅）、产品结构（I₆）和信用指数（I₇）等。该产品在每阶段的需求量及影响因素指标如下表 5.2 所示。

表 5.2 各阶段历史需求及影响因素指标

月	成本	季节系数	销售力度	市场特征	进店人数	产品结构	信用指数	销量
1	1299	0.561	1	0.98	4805	0.15	0.99	37
2	1499	0.834	0.8	0.95	4340	0.14	0.98	55
3	1499	1.122	0.8	0.96	4020	0.14	0.95	74
4	1499	1.061	0.8	0.9	3968	0.11	0.88	70
5	1499	1.258	0.8	0.96	3451	0.13	0.88	83
6	999	1.455	0.9	0.94	4080	0.14	0.85	96
7	999	1.365	0.9	0.89	4495	0.13	0.87	90
8	1499	1.441	0.4	0.85	4371	0.14	0.9	95
9	1499	1.274	0.4	0.75	3750	0.12	0.81	84
10	1499	1.319	0.3	0.79	4154	0.13	0.77	87
11	1299	1.381	0.3	0.77	4247	0.11	0.79	91
12	1299	0.940	0.1	0.75	3906	0.12	0.74	62
13	1299	0.743	0.1	0.75	3627	0.14	0.69	49
14	1299	0.622	0.1	0.68	3286	0.14	0.71	41

采用多变量支持向量机需求预测模型对该电子产品下阶段的需求进行预测，具体步骤如下：

（1）利用表 5.2 建立决策数据模型，然后通过阈值法将模型中的属性特征化，得到如下决策表（见表 5.3）

表 5.3 影响因素决策表

U	X							D
	I1	I2	I3	I4	I5	I6	I7	
1	0	0	1	1	1	1	1	0
2	1	0	1	1	1	1	1	0
3	1	0	1	1	1	1	1	0
4	1	0	1	1	0	0	1	0
5	1	1	1	1	0	1	1	1
6	0	1	1	1	1	1	1	1
7	0	1	1	1	1	1	1	1
8	1	1	0	1	1	1	1	1
9	1	1	0	0	0	0	0	1
10	1	1	0	0	1	1	0	1
11	0	1	0	0	1	0	0	1
12	0	0	0	0	0	0	0	0
13	0	0	0	0	0	1	0	0
14	0	0	0	0	0	1	0	0

注：对每个属性设定一个阈值，1 表示达到标准，0 表示没有达到标准。

(2) 利用式 (5.3) 计算各个影响因素相对于需求的重要度，可知制造成本 (I_1)、季节变化 (I_2)、销售力度 (I_3)、市场特征 (I_4) 和进店人数 (I_5) 相对于该电子产品市场需求的重要度较高，其余影响因素影响程度较弱，因而是冗余的，故而将其从特征参数集中剔除掉，得到最终的影响因素集，即 $X^* = (I_1, I_2, I_3, I_4, I_5)$ 。

(3) 根据分析，把影响该电子产品市场需求的主要因素与对应的需求值组成训练样本对，作为 SVM 的输入项，通过计算机仿真运算，求解多变量 SVM 模型中回归函数的参数，然后将得到的最优参数带入模型中，并将测试数据样本放入 SVM 模型中进行预测，得到相应的预测值。最后通过对比单变量 SVM 模型预测效果来说明多变量 SVM 预测模型在供应链需求预测中的性能。其中在不同算法下的预测需求值与实际需求值对比情况如下图 5.5、5.6 和 5.7 所示。




图 5.5 单变量 SVM 模型需求拟合数据图




图 5.6 多变量 SVM 模型需求拟合数据图




图 5.7 多变量 SVM 模型需求预测数据图

从图 5.5 可以看出，单变量 SVM 模型预测波动较大，在某些时间段甚至明显偏离实际的市场需求；而图 5.6、5.7 清晰的显示了多变量 SVM 模型对市场需求具有较好的拟合度，预测结果和实际需求较为接近，基本反映了该产品的实际市场需求。为了更好的比较两种模型的预测性能，分别计算两种预测方法需求预测值的均方根误差。如下表 5.4 所示。

表 5.4 单变量 SVM 模型与多变量 SVM 模型预测误差比较

模型	单变量 SVM 模型	多变量 SVM 模型
均方根误差 (RMSE)	14.8551	1.5320

表 5.4 中的数据进一步说明了多变量 SVM 预测误差较小，整体效果良好，虽然不能完全接近实际值，而是以非常小的振幅在实际值附近波动，这是由于样本数据残留的随机性导致的。可见，多变量 SVM 预测模型在实际生产运作中也能够获得较为准确的预测效果，同时表明综合考虑多种影响因素构造的 SVM 需求预测模型使得预测更加精确。

5.2.2 牛鞭效应分析

为了进一步探讨多变量需求预测对供应链中牛鞭效应的影响，本章在上一节讨论的电子产品销量预测的基础上对多变量支持向量机预测模型下的牛鞭效应进行量化分析，

根据上文可知该产品在单变量支持向量机和多变量支持向量机下的预测结果，通过预测结果计算出牛鞭效应，结果如下表 5.5 所示：

表 5.5 单变量 SVM 与多变量 SVM 的牛鞭效应对比

月份	实际销量	预测销量		牛鞭效应	
		多变量 SVM	单变量 SVM	多变量 SVM	单变量 SVM
1	37	37	43	0	0.162162
2	55	53	56	0.036364	0.018182
3	74	72	71	0.027027	0.040541
4	70	71	86	0.014286	0.228571
5	83	83	99	0	0.192771
6	96	95	107	0.010417	0.114583
7	90	91	110	0.011111	0.222222
8	95	96	106	0.010526	0.115789
9	84	84	98	0	0.166667
10	87	85	87	0.022989	0
11	91	87	75	0.043956	0.175824
12	62	63	63	0.016129	0.016129
13	49	50	53	0.020408	0.081633
14	41	40	44	0.02439	0.073171
15	40	37	38	0.075	0.05
16	35	34	33	0.028571	0.057143
17	26	27	29	0.038462	0.115385
牛鞭效应平均值				0.022331	0.107692

由表 5.5 中数据可知，当考虑多因素的需求预测时，每个阶段的牛鞭效应都远远小于采用单变量需求预测时产生的牛鞭效应，而在图 5.8 中我们可以清晰的看到多变量 SVM 需求预测下的牛鞭效应基本在零附近波动，其变化幅度远远小于单变量 SVM 预测下的牛鞭效应。实验结果表明，多变量 SVM 需求预测不仅提高了预测的精度，同时使得供应链中牛鞭效应也得到了有效的缓解与控制。

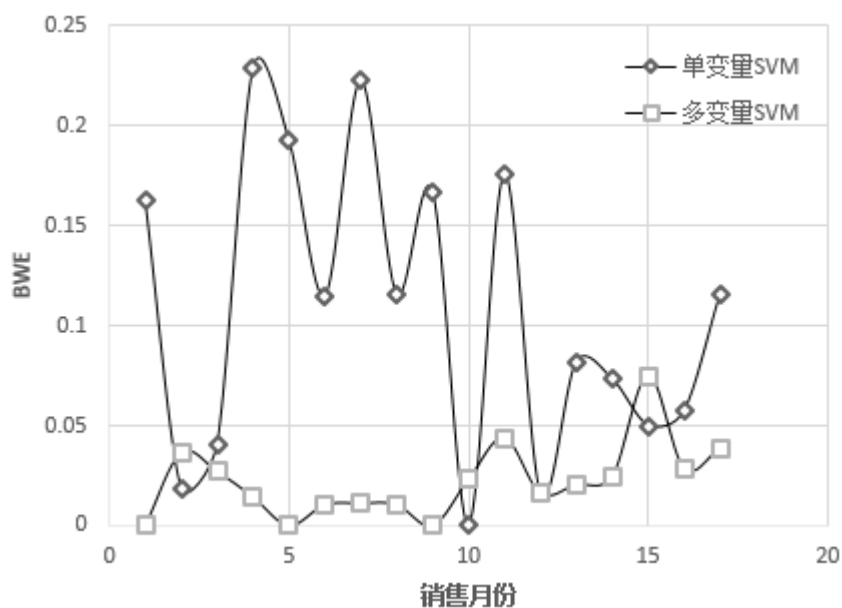


图 5.8 单变量 SVM 与多变量 SVM 下牛鞭效应的波动比较

5.3 本章小结

供应链需求预测问题是一个比较复杂的问题，若仅仅依靠单一的时间序列历史数据无法准确的预测下一阶段的市场需求，针对影响市场需求因素繁多，本章采用信息熵理论选取主要特征因素，考虑了多个变量的相互影响，在此基础上提出了基于多变量支持向量机的需求预测方法，实现了多变量预测，最大程度挖掘了各种有效信息。在 MATLAB 平台构造多变量 SVM 需求预测模型，并通过计算机模拟仿真进行算例分析。结果表明，运用多变量 SVM 预测模型对多个因素影响下的市场需求具有较好的预测性能，有效的提高了预测精度。并且通过对多变量 SVM 预测模型下牛鞭效应的分析说明了优化需求预测可以有效的缓解供应链中的牛鞭效应。

结 论

需求预测作为供应链管理的首要环节,是影响牛鞭效应的关键因素之一,如何提高预测的精确度来缓解牛鞭效应一直是该领域的研究热点,同时也是供应链管理中急需解决的问题。本文通过结合大数据理论,探讨在大数据背景下供应链结构、需求预测以及牛鞭效应的变化。首先针对大数据的各个特征,分析在大数据背景下供应链的结构体系,并用 Agent 系统对其进行抽象模拟,提出基于 Multi-Agent 系统的供应链模型。然后,在此供应链模型的基础上对大数据背景下供应链需求预测和牛鞭效应进行研究,以期可以得到更精确的需求预测来缓解供应链中的牛鞭效应。本文的研究成果及结论主要有:

(1) 结合大数据理论,通过引入 Agent 原理和 Multi-Agent 系统来解决供应链成员之间信息共享问题以及提高供应链对分布式环境的适应能力;最后在以上的研究基础上提出大数据背景下基于 Multi-Agent 系统的供应链模型。

(2) 根据大数据背景下供应链的结构和市场需求的特征,提出了基于遗传算的支持向量机预测模型,首先介绍了一般的传统支持向量机模型,讨论模型中参数对拟合预测的影响。然后在此基础上提出利用遗传算法对原有模型的参数进行优化改进,构造基于遗传算法的支持向量机预测模型。该模型充分考虑在大数据背景下企业需快速反应市场需求的特点,克服了传统的预测模型在面对数据不确定、波动大的情况下无法迅速准确的响应市场需求的缺陷,加快了预测速度,降低了需求预测的误差,同时对牛鞭效应也具有一定的缓解作用。

(3) 为了适应大数据环境下供应链需求预测的特点,通过信息熵理论构建多变量需求指标体系,提出多变量支持向量机预测模型。并在多变量的支持向量机预测基础上引入 BP 神经网络来减少预测误差,提高模型对数据的拟合精度。通过结合两种算法模型的优点,对大数据环境下供应链进行精确的需求预测。弥补了该模型在高维的情况下泛化能力不足的缺陷,降低了需求预测的误差,为大数据背景下供应链需求预测提供有效的预测方法,进而大大的缓解了供应链中的牛鞭效应。

本文完成了一定的研究工作,但由于大数据理论在国内研究还比较少,缺乏研究成果,尤其是在大数据背景下探讨供应链的相关内容,加之时间限制,作者水平有限,论文仍存在一些不足之处:

(1) 大数据是一个非常复杂的理论体系,在大数据的背景下研究探讨需求预测和牛鞭效应没有全面的考虑大数据的特点,如非结构化数据的处理,降低了需求预测模型

的实用性，研究略显粗浅。

（2）在分析供应链牛鞭效应时，没有从供应链的整体出发，只从需求预测的角度对牛鞭效应进行了量化分析，缺乏全面整体的对供应链牛鞭效应研究。

（3）论文主要研究了大数据背景下供应链需求预测和牛鞭效应问题，目前的研究还主要侧重于理论和方法，在实际的大数据背景下需要进一步验证，要将模型真正的运用到供应链企业中，需要进一步的证明和调整。

参 考 文 献

- [1] Forrester J. Industrial Dynamic. U S A. New York MIT Press .1961:288-291.
- [2] Sterman J D. Modeling managerial behavior: Misperceptions of feedback in a dynamic decision making experiment [J] .Management Science, 1989, 35:321-339.
- [3] Towill R D. Industrial dynamics modeling of supply chains [J] .International Journal of Physical Distribution & Logistics Management, 1996 , 26(2):23-41.
- [4] Kahn J. Inventory and the volatility of production [J] .American Economic Review, 1987, 77(4):667-779.
- [5] Sterman J D. The beer distribution game [A].In Heicie J, Meile L, eds. Games and Exercises for Operations Management [M]. New Jersey :Prentice Hall , 1995.101-112.
- [6] Lee H, Padmanabhan V, Whang S. The bullwhip effect in supply chains [J] .Sloan Management Rev, 1997 , 38:93-102.
- [7] Chen F, Drezner Z, Ryan J K, et al. Quantifying the bullwhip effect in a simple supply chain: The impact of forecasting, lead times, and information [J]. Management Science, 2000, 46:436-443.
- [8] Towill D.R. Supply Chain Dynamics [J]. International Journal of Computer Integrated Manufacturing, 1991, 4(3):197-208.
- [9] Metters R. Quantify the bullwhip effect in the supply chains [J]. Journal of Operations Management, 1997, 15:89-100.
- [10] Akhtar T, Gang D. An Optimization Model for Mitigating Bullwhip-effect in a Two-echelon Supply Chain[J]. Procedia - Social and Behavioral Sciences, 2014, 138:289-297.
- [11] Xu K, Dong Y, Evers P T. Towards better coordination of the supply chain [J]. Transportation Research, 2001, Part E 37:35-54.
- [12] Yu Z, Yan H, Cheng T C. Benefits of information sharing with supply chain partnerships[J]. Industrial Management & Data Systems, 2001, 101(3):114-119.
- [13] Hofmann E. Big data and supply chain decisions: the impact of volume, variety and velocity properties on the bullwhip effect[J]. Production Research, 2015:1-19.
- [14] 邵晓峰, 季建华, 黄培清. 供应链中的牛鞭效应分析 [J]. 东华大学学报 (自然科学版) , 2001, 27(4):119-124.
- [15] 傅烨, 郑绍濂. 供应链中的牛鞭效应成因及对策分析 [J]. 管理工程学报, 2002, (1):82-83.
- [16] 达庆利, 张钦, 沈厚才. 供应链中牛鞭效应问题研究 [J]. 管理科学学报, 2003, 6(3):86-93.
- [17] 万杰, 寇纪淞, 李敏强. 需求信息预测与处理中的牛鞭效应 [J]. 天津大学学报, 2003, 17(4):28-32.
- [18] 李翀, 刘思峰, 方志耕. 供应链网络系统的牛鞭效应时滞因素分析与库存控制策略研究 [J]. 中国管理科学, 2013, 21(3):107-112.
- [19] 刘红, 王平. 基于不同预测技术的供应链牛鞭效应分析 [J]. 系统工程理论与实践, 2007, 7:26-33.
- [20] Dominguez R, Cannella S, Jose M. Framinan. The impact of the supply chain structure on bullwhip effect [J]. Applied Mathematical Modelling, 2015, 39:7309-7325.
- [21] Roberto Domingueza, Jose M. Framinana Salvatore Cannellab. Serial vs. divergent supply chain networks: a comparative analysis of the bullwhip effect [J]. Production Research, 2014, 52(7):2197-2210.
- [22] Ray Y. Zhonga, George Q. Huang, Shulin Lan, et al. A Big Data Approach for Logistics Trajectory Discover from RFID-enabled Production Data [J]. Production Economics, 2015, 165:260-272.
- [23] Hu Y. A genetic-algorithm-based remnant grey prediction model for energy demand forecasting [J]. Plos One, 2017, 12(10):1-11.
- [24] Ming L, Shalang L, Qian T. Intermittent demand forecasting with fuzzy markov chain and multi aggregation prediction algorithm [J]. Journal Of Intelligent & Fuzzy Systems, 2016, 31(6):2911-2918.
- [25] Liu Y, Ju W, Zhao J, et al. Product life cycle based demand forecasting by using artificial bee colony algorithm optimized two-stage polynomial fitting [J]. Journal Of Intelligent & Fuzzy Systems, 2016, 31(2):825-836.
- [26] Noori R. Uncertainty analysis of support vector machine for online prediction of five-day biochemical oxygen demand [J]. Journal of Hydrology, 2015, 527: 833-843.

- [27] Chen,Y, Tan,H. Short-term prediction of electric demand in building sector via hybrid support vector regression[J]. Applied Energy,2017,204:1363-1374.
- [28] Cao J, Jiang Z, Wangk K. Customer demand prediction of service-oriented manufacturing using the least square support vector machine optimized by particle swarm optimization algorithm[J]. Engineering Optimization,2017,49(7):1197-1210.
- [29] Penaguzman C, Melgarejo J, Prats,D. Forecasting Water Demand in Residential, Commercial, and Industrial Zones in Bogotá, Colombia, Using Least-Squares Support Vector Machines[J]. Mathematical Problems in Engineering,2016,1-10.
- [30] Weide,L, Demeng,K, Jinran Wu. A Novel Hybrid Model Based on Extreme Learning Machine, k-Nearest Neighbor Regression and Wavelet Denoising Applied to Short-Term Electric Load Forecasting[J]. Energies,2017,10(5):1-16.
- [31] Adamowski JF. Peak Daily Water Demand Forecast Modeling Using Artificial Neural Networks[J]. Journal of Water Resources Planning & Management,2008,134(2):119-128.
- [32] Wang G. Research On Supply Chain Demand Prediction Based On BP Neural Network Algorithm[J]. Inmateh - Agricultural Engineering,2013,40(2):27-34.
- [33] 卢阳.基于灰色线性回归组合模型的金融预测方法[J].统计与决策,2017,(10):91-93.
- [34] 寇瑜琨,黄梦醒,陈泓宇.基于 Petri 网和 Agent 的供应链需求预测模型[J].计算机工程与设计,2015,36(09):2496-2500.
- [35] 宋士豹,杨淑莹.基于邻近相点聚类分析的多变量局域多步预测[J].计算机应用研究,2018,(08):1-7.
- [36] 代亮,许宏科,梁殿鹏等.基于 MapReduce 的多元线性回归预测模型[J].计算机应用,2014,34(07):1862-1866.
- [37] 黄邦菊,林俊松,郑潇雨等.基于多元线性回归分析的民用运输机场旅客吞吐量预测[J].数学的实践与认识,2013,43(04):172-178.
- [38] 孙涵,杨普容,成金华.基于 Matlab 支持向量回归机的能源需求预测模型[J].系统工程理论与实践,2011,31(10):2001-2007.
- [39] 陈果,杨虞微.航空发动机复杂磨损趋势的神经网络多变量预测模型[J].中国机械工程,2007,(01):70-74.
- [40] 刘红,王平.基于不同预测技术的供应链牛鞭效应分析[J].系统工程理论与实践,2007,(07):26-33.
- [41] 王惠文,孟洁.多元线性回归的预测建模方法[J].北京航空航天大学学报,2007,(04):500-504.
- [42] 丁松,党耀国,徐宁,朱晓月.基于驱动因素控制的 DFCGM(1,N)及其拓展模型构建与应用[J].控制与决策 2017:1-6.
- [43] 章杰宽,朱普选.动态粒子群算法优化灰色神经网络的旅游需求预测模型研究[J].管理评论,2013,25(03):60-66.
- [44] 顾嘉运,刘晋飞,陈明.基于 SVM 的大样本数据回归预测改进算法[J].计算机工程,2014,40(01):161-166.

致 谢

时光荏苒，白驹过隙，转眼间，近三年的研究生学习生涯即将告一段落，回首往昔，一切都历历在目记忆犹新，老师的教诲，同学的鼓励，父母的叮嘱至今都萦绕耳畔。感念过往，三年里的点点滴滴沉淀成了我人生中最宝贵的回忆。值此毕业论文完成之际，我谨向所有关心、爱护、帮助我的人们致以最诚挚的感谢与最美好的祝愿。

本论文是在导师荆浩教授的悉心指导下完成的。在整个学习和研究阶段，老师严谨求实的治学态度，平易近人的学者风范和朴实无华的生活作风对我影响深远；深厚的学术功底，诲人不倦的高尚师德更使我受益匪浅。此外老师不仅授我以文，而且教我为人处世之道，虽仅两载有余，却让我终生受益无穷。本论文从确定研究问题、开展研究工作直至完成论文写作与修改，每一个环节无不倾注了老师的智慧与心血。在此我向我的恩师荆浩教授表示最深切的感谢和祝福！

本论文的完成也离不开其他各位来时、同学和朋友的关心与帮助，在此也要感谢沈阳航空航天大学三年来的培养，感谢经济与管理学院各位老师对论文开题、初稿、预答辩期间所提出的宝贵意见，同时还要感谢在一起度过研究生生活的各位舍友和所有同窗好友，感谢你们在我迷惘困惑时对我的关心和支持，你们热情的帮助和鼓励使我得以更加顺利的完成论文。感谢所有在我三年学习和生活中陪伴我一起成长一起欢笑的小伙伴，因为你们生活才更加丰富多彩，让我拥有一段愉悦而难忘的求学历程。

最后，我要特别感谢我的父母多年来给予我无微不至的关怀与照顾，感谢他们在生活上和精神上给我的支持与鼓励，这也是我一直不断前行的动力源泉，对于他们辛勤的付出，我将铭记肺腑！

研究生学习生涯暂告一段路，但求知的道路永无止境。两年多的校园生活带给我许多珍贵的财富，教会了我许多难能品质。德能并进，勇毅翔远——这八字箴言将伴随我在以后得人生道路上，勇敢地不断前行。

刘垭于沈阳航空航天大学

2018年1月2日

攻读硕士期间发表（含录用）的学术论文

- [1]荆浩,刘垚,徐娴英.数字化使能的商业模式转型:一个制造企业的案例研究[J].科技进步与对策,2017,34(03):93-97.
- [2]荆浩,刘垚,祁宁.“互联网+”时代数据驱动商业模式案例分析[J].商业经济研究,2016(11):38-40.
- [3]荆浩,刘垚.尚品宅配:“互联网+”的商业模式创新[J].企业管理,2016(02):107-109.